

Aprendizaje de Máquinas

Examen Otoño 2025

Índice de Contenidos

Índice de Figuras

1.	Diferentes métodos de reducción de dimensionalidad aplicados a una nube de datos en forma de Rollo Suizo.	13
2.		14

P1. Modelo Bayesiano Beta-Bernoulli (35 %)

Considere N ensayos de una v.a. Bernoulli i.i.d. $X_1, \dots, X_N$ con $X_i \in \{0, 1\}$ y probabilidad de éxito $\theta \in (0, 1)$. Se utiliza un Prior **Beta**(α, β) para θ :

$$p(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

Después de observar los datos $\mathcal{D} = \{x_1, \dots, x_N\}$, se denota a $S_N = \sum_{i=1}^N x_i$ como el número de éxitos.

- (a) (3 puntos) Demuestre que la **distribución posterior** para θ es también una distribución **Beta**, específicamente:

$$p(\theta|\mathcal{D}) = \text{Beta}(\theta; \alpha', \beta')$$

donde los **parámetros actualizados** son:

$$\begin{aligned}\alpha' &= S_N + \alpha \\ \beta' &= N - S_N + \beta\end{aligned}$$

Respuesta:

La verosimilitud de los datos es:

$$p(\mathcal{D}|\theta) = \prod_{i=1}^N \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{S_N} (1 - \theta)^{N-S_N}.$$

Aplicando la regla de Bayes:

$$p(\theta|\mathcal{D}) \propto p(\mathcal{D}|\theta) p(\theta) = \theta^{S_N} (1 - \theta)^{N-S_N} \cdot \theta^{\alpha-1} (1 - \theta)^{\beta-1} = \theta^{S_N+\alpha-1} (1 - \theta)^{N-S_N+\beta-1}.$$

Esto corresponde a una distribución Beta con parámetros actualizados:

$$\alpha' = S_N + \alpha, \quad \beta' = N - S_N + \beta.$$

- (b) (1 punto) Interprete los **parámetros de la distribución posterior**, α' y β' . ¿Cómo reflejan la combinación de la información **proveniente del prior** (representada por α y β) y la **información obtenida de los datos observados** (S_N y N)? Describa conceptualmente cómo “aprende” el modelo bayesiano al actualizar estos parámetros.

Se sabe que la **media de la distribución posterior** $\text{Beta}(\alpha', \beta')$ es un **estimador puntual bayesiano común** para θ , dado por:

$$\hat{\theta}_{\text{Bayes}} = \mathbb{E}[\theta|\mathcal{D}] = \frac{\alpha'}{\alpha' + \beta'} = \frac{S_N + \alpha}{N + \alpha + \beta}$$

Respuesta:

Los parámetros α' y β' combinan la información del prior y de los datos:

- α y β representan la información previa sobre θ .

- S_N y $N - S_N$ representan la información aportada por los datos observados.

El modelo “aprende” actualizando el prior con evidencia de los datos; más observaciones conducen a una posterior más concentrada alrededor de la proporción observada de éxitos S_N/N .

La media de la distribución posterior es:

$$\hat{\theta}_{\text{Bayes}} = \mathbb{E}[\theta|\mathcal{D}] = \frac{\alpha'}{\alpha' + \beta'} = \frac{S_N + \alpha}{N + \alpha + \beta}.$$

- (c) (1 punto) Basándose en la fórmula para $\hat{\theta}_{\text{Bayes}}$, explique la **interpretación de los hiperparámetros del prior**, α y β , como “**pseudo-observaciones**” o “**pseudo-conteos**”.

- ¿Qué representa la suma $\alpha + \beta$ en términos de la “**fuerza**” de la **creencia a priori**?

Respuesta:

La suma $\alpha + \beta$ representa la **fuerza total del prior**, equivalente al número de “**pseudo-observaciones**” que aporta la creencia a priori. Un valor grande de $\alpha + \beta$ indica un prior fuerte y difícil de modificar con los datos observados.

- ¿Cómo afecta una **creencia a priori fuerte** (i.e., $\alpha + \beta$ grande) a la **sensibilidad del estimador** $\hat{\theta}_{\text{Bayes}}$ frente a los datos observados S_N/N ?

Respuesta:

Si $\alpha + \beta$ es grande, el prior domina la actualización bayesiana y el estimador $\hat{\theta}_{\text{Bayes}}$ se vuelve **poco sensible** a los datos. En este caso, incluso cambios grandes en S_N/N producen variaciones pequeñas en la estimación. Por el contrario, si $\alpha + \beta$ es pequeño, el estimador es **más sensible** y los datos influyen de manera mucho más marcada que el prior.

- La suma $\alpha + \beta$ representa el número efectivo de **pseudo-observaciones**, o la “fuerza” de la creencia a priori.
- Una **creencia a priori fuerte** (i.e., $\alpha + \beta$ grande) reduce la sensibilidad del estimador $\hat{\theta}_{\text{Bayes}}$ frente a los datos observados, ya que los pseudo-conteos pesan tanto como los datos reales en la media posterior. Por el contrario, un prior débil ($\alpha + \beta$ pequeño) permite que los datos dominen la estimación.

Considere dos **priors no informativos comunes**: el prior **Uniforme**, $\text{Beta}(1, 1)$, y el prior de **Jeffreys**, $\text{Beta}(0.5, 0.5)$. Las medias posteriores correspondientes son:

$$\hat{\theta}_{\text{Uniforme}} = \frac{S_N + 1}{N + 2} \quad (\text{Regla de Laplace})$$

$$\hat{\theta}_{\text{Jeffreys}} = \frac{S_N + 0.5}{N + 1}$$

El estimador de **Máxima Verosimilitud (EMV)** es $\hat{\theta}_{\text{MV}} = S_N/N$.

4. (1 punto) Compare los estimadores $\hat{\theta}_{\text{Uniforme}}$ y $\hat{\theta}_{\text{Jeffreys}}$ con el estimador $\hat{\theta}_{\text{MV}}$.

- Si se observan $N = 2$ ensayos y ambos son fracasos ($S_N = 0$), ¿cuáles son los valores de $\hat{\theta}_{\text{MV}}$, $\hat{\theta}_{\text{Uniforme}}$ y $\hat{\theta}_{\text{Jeffreys}}$?
- Interprete las diferencias entre estos estimadores en este caso ($S_N = 0$). ¿Qué propiedad útil tienen los estimadores bayesianos (incluso con priors vagos) que el EMV no posee, especialmente cuando

N es pequeño o cuando $S_N = 0$ o $S_N = N$? ¿Cómo se relaciona esto con evitar predicciones extremas?

- ¿Qué sucede cuando el número de observaciones $N \rightarrow \infty$?

Respuesta:

a) Para $N = 2$ y $S_N = 0$ (dos fracasos):

$$\hat{\theta}_{\text{MV}} = \frac{S_N}{N} = \frac{0}{2} = 0, \quad \hat{\theta}_{\text{Uniforme}} = \frac{S_N + 1}{N + 2} = \frac{0 + 1}{2 + 2} = \frac{1}{4} = 0.25,$$

$$\hat{\theta}_{\text{Jeffreys}} = \frac{S_N + 0.5}{N + 1} = \frac{0 + 0.5}{2 + 1} = \frac{0.5}{3} = \frac{1}{6} \approx 0.1667.$$

b) Interpretación de las diferencias:

- El **EMV** devuelve 0 porque no observa éxitos; esto conduce a estimaciones extremas (0 o 1) cuando $S_N \in \{0, N\}$.
- Los estimadores bayesianos con priors no informativos (Beta(1, 1) y Beta(1/2, 1/2)) **incorporan pseudo-conteos** y realizan un **suavizado** (smoothing). Por eso $\hat{\theta}_{\text{Uniforme}}$ y $\hat{\theta}_{\text{Jeffreys}}$ son estrictamente positivos y se alejan de valores extremos.
- Esta propiedad es útil cuando N es pequeño o cuando $S_N = 0$ o $S_N = N$, porque evita asignar probabilidad cero (o uno) a eventos futuros. En problemas de predicción esto evita que la probabilidad predictiva de futuros éxitos/fracaso sea exactamente 0 o 1 (regla de sucesión de Laplace).
- Nota: Jeffreys (Beta(1/2, 1/2)) es menos informativo que la uniforme en el sentido de que introduce menor pseudo-conteo efectivo (0.5 vs 1), por eso su estimador queda entre EMV y la regla de Laplace.

c) Comportamiento cuando $N \rightarrow \infty$:

- Por consistencia y por el teorema de Bernstein–von Mises, la influencia del prior se desvanece a medida que crece la muestra. Los tres estimadores $\hat{\theta}_{\text{MV}}, \hat{\theta}_{\text{Uniforme}}, \hat{\theta}_{\text{Jeffreys}}$ **convergen a** S_N/N y, en probabilidad, al valor verdadero θ cuando $N \rightarrow \infty$.
- En otras palabras, para muestras grandes la diferencia entre los estimadores es despreciable.

P2. Preguntas Conceptuales (25 %)

Responda un **máximo de 8** de las siguientes preguntas.

- (a) ¿Cuál es el rol del **parámetro de regularización** C en un **SVM de margen suave**? Discuta cómo afecta a la **amplitud del margen** y al compromiso **sesgo-varianza**.

Respuesta:

Un valor grande de C impone una penalización alta a los puntos mal clasificados, llevando al modelo a *ajustarse más estrictamente* a los datos.

Un valor pequeño de C permite más violaciones del margen (mayor tolerancia a errores), favoreciendo un margen más amplio.

1. Efecto en el margen:

- C grande $\Rightarrow$ margen más estrecho, menos errores permitidos.
- C pequeño $\Rightarrow$ margen más amplio, mayor flexibilidad frente a errores.

2. Compromiso sesgo-varianza:

- C grande $\Rightarrow$ bajo sesgo, alta varianza (riesgo de sobreajuste).
- C pequeño $\Rightarrow$ mayor sesgo, baja varianza (modelo más estable).

- (b) ¿Cómo maneja un **árbol de decisión** como **CART** las **características continuas**? Describa el proceso que sigue para encontrar el **punto de corte óptimo**.

Respuesta:

En un árbol de decisión tipo CART, las características continuas se manejan mediante **puntos de corte** que dividen el espacio en regiones del tipo

$$x_j \leq t \quad \text{y} \quad x_j > t.$$

El procedimiento es el siguiente:

- Para una característica continua x_j , se ordenan sus valores de menor a mayor.
- Se consideran como candidatos a punto de corte los valores medios entre dos observaciones consecutivas.
- Para cada punto de corte t se evalúa la **impureza resultante** del split (por ejemplo, índice Gini o entropía):

$$\text{Impureza}(t) = \frac{n_L}{n} \text{Impureza}(L) + \frac{n_R}{n} \text{Impureza}(R),$$

donde L y R son los subconjuntos izquierdo y derecho.

- El algoritmo selecciona el punto de corte t^* que **minimiza** la impureza o, equivalentemente, **maximiza la ganancia de información**.

Así, CART transforma una variable continua en una división binaria óptima según el criterio de impureza.

- (c) Compare las **suposiciones** de **K-means** y **DBSCAN** sobre la **estructura y forma de los clústeres**. ¿En qué **escenarios** preferiría usar uno sobre el otro?

Respuesta:

Suposiciones sobre la estructura de los clústeres:

- **K-means:**

- Supone que los clústeres son aproximadamente *esféricos* y de tamaño similar.
- Cada punto pertenece a un único clúster, asignado según la **distancia euclidiana al centroide**.
- Sensible a outliers y a la escala de las variables.

- **DBSCAN:**

- Supone que los clústeres son regiones de *alta densidad* separadas por regiones de baja densidad.
- Puede detectar clústeres de forma arbitraria y manejar ruido (puntos aislados).
- No requiere especificar el número de clústeres a priori.

Escenarios de uso:

- Usar **K-means** cuando los clústeres son aproximadamente esféricos, de tamaño comparable y sin muchos outliers.
- Usar **DBSCAN** cuando los clústeres tienen formas irregulares, diferentes densidades o se desea identificar puntos ruidosos/no asignables.

- (d) ¿Por qué son esenciales las **funciones de activación no lineales** en las **redes neuronales profundas**? ¿Qué pasaría si una red de múltiples capas solo usara **activaciones lineales**?

Respuesta:

Las **funciones de activación no lineales** son esenciales en redes neuronales profundas porque permiten a la red modelar **relaciones no lineales** entre las entradas y salidas.

- Sin activaciones no lineales, incluso con múltiples capas, la composición de funciones lineales sigue siendo **una función lineal**.
- Esto significa que una red profunda con solo activaciones lineales sería equivalente a una **regresión lineal simple**, perdiendo la capacidad de capturar patrones complejos en los datos.
- Por lo tanto, las activaciones no lineales (ReLU, sigmoide, tanh, etc.) permiten a la red aprender representaciones jerárquicas y funciones no lineales, solucionando problemas como XOR.

- (e) ¿Por qué el **pre-procesamiento de los datos**, como la **estandarización**, es a menudo un paso crucial antes de aplicar **K-Means**? Relacione su respuesta con la **función de costo** del algoritmo.

Respuesta:

El preprocesamiento, como la **estandarización**, es crucial antes de aplicar **K-Means** porque el algoritmo se basa en la **distancia euclidiana** para asignar puntos a los clústeres y actualizar los centroides.

- Si las variables tienen **escalas muy diferentes**, aquellas con valores mayores dominarán la distancia euclidiana, sesgando la función de costo:

$$J = \sum_{i=1}^n \sum_{k=1}^K r_{ik} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2,$$

donde $\boldsymbol{\mu}_k$ son los centroides y r_{ik} indica asignación.

- La estandarización (media cero, desviación estándar uno) asegura que todas las variables contribuyan de manera **equivalente** a la distancia, evitando que la función de costo se minimice principalmente en función de unas pocas características dominantes.
- (f) Usando el concepto de **Ganancia de Información**, explique por qué un **atributo de alta cardinalidad** (como un ID de usuario) obtendría una **ganancia máxima** pero resultaría en un **modelo inútil para generalizar**.

Respuesta:

La **ganancia de información** mide la reducción de impureza (por ejemplo, entropía) que proporciona un atributo al dividir los datos.

- Un atributo de **alta cardinalidad** (como un ID único de usuario) produce divisiones donde casi cada instancia queda en su propio nodo, eliminando completamente la impureza local.
 - Esto genera una **ganancia de información máxima**, porque cada nodo está puramente clasificado, pero el modelo **aprende memorísticamente** los datos de entrenamiento.
 - Al predecir sobre nuevos datos, el atributo no proporciona información útil, ya que los valores no vistos no existían en entrenamiento, resultando en un modelo que **no generaliza**.
- (g) ¿Bajo qué condiciones el **estimador Máximo a Posteriori (MAP)** coincide con el **estimador de Máxima Verosimilitud (EMV)**?

Respuesta:

El **estimador MAP** coincide con el **estimador de máxima verosimilitud (EMV)** cuando el **prior sobre los parámetros es uniforme** o constante.

- Recordemos que:

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} p(\theta \mid \mathcal{D}) = \arg \max_{\theta} p(\mathcal{D} \mid \theta) p(\theta).$$

- Si $p(\theta) \propto \text{constante}$, entonces

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} p(\mathcal{D} \mid \theta) = \hat{\theta}_{\text{EMV}}.$$

- En otras palabras, cuando no se introduce información previa sobre los parámetros, MAP y EMV producen el mismo estimador.

- (h) En el **clustering jerárquico**, compare los **tipos de clústeres** que tienden a favorecer los métodos de enlace **simple** (*single-linkage*), **completo** (*complete-linkage*) y el método de **Ward**.

Respuesta:

En el **clustering jerárquico**, los diferentes métodos de enlace favorecen distintos tipos de clústeres:

- **Single-linkage (enlace simple):** - Une clústeres basándose en la **distancia mínima** entre puntos de distintos clústeres. - Tiende a formar clústeres **alargados o encadenados** (efecto *chaining*).
 - **Complete-linkage (enlace completo):** - Considera la **distancia máxima** entre puntos de distintos clústeres. - Favorece clústeres **compactos y de forma más regular**, evitando cadenas largas.
 - **Ward:** - Minimiza la **suma de cuadrados dentro de cada clúster** al unirlos. - Favorece clústeres **compactos y aproximadamente esféricos**, similar a K-means en forma.
- (i) ¿Cuáles son los dos **factores principales** que los criterios de información de **Akaike (AIC)** y **Bayesiano (BIC)** buscan **equilibrar** al seleccionar un modelo?

Respuesta:

Los criterios de información **AIC** y **BIC** buscan equilibrar dos factores principales al seleccionar un modelo:

- **Calidad del ajuste:** La capacidad del modelo para explicar los datos (log-verosimilitud).
- **Complejidad del modelo:** Penalización por el número de parámetros, para evitar sobreajuste.

En fórmula general:

$$\text{AIC} = -2 \log L + 2k, \quad \text{BIC} = -2 \log L + k \log n,$$

donde L es la verosimilitud, k el número de parámetros y n el tamaño de la muestra.

- (j) ¿Qué información entregan la **curva ROC** y el **área bajo la curva (AUC)**? ¿Por qué la **métrica AUC** es a menudo preferible a la **exactitud (accuracy)** en problemas con **clases desbalanceadas**?

Respuesta:

Curva ROC: Muestra la relación entre la **tasa de verdaderos positivos (TPR)** y la **tasa de falsos positivos (FPR)** para distintos umbrales de decisión de un clasificador.

Área bajo la curva (AUC): Resume la capacidad del modelo para distinguir entre clases en un solo valor entre 0 y 1; un AUC cercano a 1 indica excelente discriminación.

Ventaja sobre exactitud:

- La **exactitud** puede ser engañosa en problemas con **clases desbalanceadas**, ya que un modelo que predice siempre la clase mayoritaria puede tener alta exactitud pero no discrimina correctamente la clase minoritaria.
- El **AUC** evalúa el rendimiento del clasificador en todas las clases y umbrales, siendo insensible a la proporción de clases, por lo que es más robusta en escenarios desbalanceados.

- (k) Al visualizar datos con **t-SNE**, ¿por qué **no es correcto interpretar las distancias relativas** entre clústeres bien separados en el mapa de baja dimensión? ¿Qué **aspecto del algoritmo** causa este efecto?

Respuesta:

En **t-SNE**, las distancias relativas entre clústeres bien separados en la proyección de baja dimensión **no reflejan necesariamente las distancias reales en el espacio original**.

- Esto ocurre porque t-SNE **prioriza preservar las distancias locales** (vecindad de puntos cercanos) y convierte las distancias grandes en probabilidades muy pequeñas, perdiendo información global.
- Como consecuencia, los clústeres pueden aparecer muy alejados o comprimidos en el mapa de baja dimensión sin que ello represente su verdadera separación en el espacio original.

- (l) Los **árboles de decisión** particionan el espacio de características en **regiones hiper-rectangulares**. ¿Cómo afecta esta propiedad a su capacidad para modelar **relaciones lineales diagonales** (ej. $x_1 + x_2 > c$)?

Respuesta:

Los árboles de decisión crean particiones **hiper-rectangulares** alineadas con los ejes de las variables, por lo que:

- Para modelar relaciones **lineales diagonales** como $x_1 + x_2 > c$, un árbol requiere **múltiples splits** que aproximen la diagonal mediante pasos rectangulares.
- Esto conduce a **regiones en forma de escalera** y puede necesitar un árbol **muy profundo** para capturar la relación con precisión.
- En resumen, los árboles modelan mal relaciones lineales diagonales a menos que se incremente la complejidad, lo que puede causar sobreajuste.

- (m) ¿Una **red neuronal con una única capa oculta** siempre es capaz de aprender cualquier **función continua**? Discuta en el contexto del **Teorema de Aproximación Universal** y sus **limitaciones prácticas**.

Respuesta:

Según el **Teorema de Aproximación Universal**, una **red neuronal con una sola capa oculta** y una activación no lineal apropiada puede aproximar **cualquier función continua** definida en un dominio compacto con **precisión arbitraria**.

• **Limitaciones prácticas:**

- La capa oculta puede requerir un **número muy grande de neuronas** para funciones complejas, haciendo el entrenamiento difícil.
- El teorema garantiza la existencia de pesos adecuados, pero **no indica cómo encontrarlos** mediante optimización.
- En la práctica, problemas de **sobreajuste, estabilidad numérica y eficiencia computacional** limitan su aplicabilidad.

P3. Verdadero o Falso (20 %)

Determine si las siguientes afirmaciones son verdaderas o falsas y justifique **brevemente**. (0.6 ptos c/u)

- (a) El algoritmo **K-means** es robusto a la inicialización de los centroides y garantiza la convergencia al óptimo global de la función de costo WCSS (**inercia**).

Respuesta: Falso.

- K-means **no es robusto** a la inicialización de los centroides; diferentes inicializaciones pueden conducir a **distintos mínimos locales** de la función de costo WCSS.
- El algoritmo garantiza **convergencia a un mínimo local**, pero **no necesariamente al óptimo global**.

- (b) En un **SVM con kernel RBF**, $K(\vec{x}_i, \vec{x}_j) = \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|^2)$, un valor muy **pequeño de γ** tiende a producir un modelo más complejo y propenso al **sobreajuste**.

Respuesta: Falso.

- En un SVM con kernel RBF, un valor muy **pequeño de γ** implica que la función kernel varía lentamente con la distancia, es decir, los puntos lejanos se consideran similares.
- Esto genera un modelo **más suave**, con **baja complejidad** y tendencia al **subajuste**, no al sobreajuste.
- Por el contrario, un **valor grande de γ** produce un modelo altamente flexible, capaz de ajustarse a ruido y, por lo tanto, propenso al sobreajuste.

- (c) Un ensamble de modelos tipo **Boosting**, como **AdaBoost**, entrena a sus modelos base de manera secuencial, donde cada nuevo modelo se enfoca en corregir los errores de los modelos anteriores.

Respuesta: Verdadero.

- En Boosting (ej. AdaBoost), los modelos base se entrenan **secuencialmente**.
- Cada nuevo modelo presta más atención a los **errores cometidos por los modelos anteriores**, ajustando los pesos de las instancias para mejorar la predicción global.

- (d) La función de pérdida de una red neuronal profunda con funciones de activación no lineales es, en general, una función no convexa con respecto a sus pesos, lo que implica la posible existencia de **múltiples mínimos locales**.

Respuesta: Verdadero.

- En redes neuronales profundas con activaciones no lineales, la función de pérdida es **no convexa** respecto a los pesos.
- Esto implica que pueden existir **múltiples mínimos locales** y mesetas, lo que hace que el entrenamiento dependa de la inicialización y del algoritmo de optimización utilizado.

- (e) El objetivo del **Análisis de Componentes Principales (PCA)** es encontrar las proyecciones que maximizan la **separación entre las clases** de un conjunto de datos.

Respuesta: Falso.

- El **PCA** es una técnica de **reducción de dimensionalidad no supervisada** que busca las direcciones de máxima varianza en los datos, **sin considerar las etiquetas de clase**.
 - La separación entre clases no es optimizada; para eso se usaría un método supervisado como **LDA (Linear Discriminant Analysis)**.
- (f) Para un número de observaciones $N > 8$, el término de penalización por complejidad del **Criterio de Información Bayesiano (BIC)** es siempre mayor que el del **Criterio de Información de Akaike (AIC)**.

Respuesta: Verdadero.

- El BIC penaliza la complejidad de un modelo mediante $k \log N$, mientras que el AIC utiliza $2k$, donde k es el número de parámetros y N el tamaño de la muestra.
 - Para $N > 8$, se cumple que $\log N > 2$, por lo que la penalización de BIC siempre es **mayor** que la de AIC, favoreciendo modelos más simples.
- (g) La suposición **naive** en el clasificador **Naive Bayes** es que las características son marginalmente independientes entre sí.

Respuesta: Falso.

- La suposición **naive** de Naive Bayes es que las características son **condicionalmente independientes dado la clase**, no marginalmente independientes.
- Es decir, para una clase C , se asume:

$$P(X_1, X_2, \dots, X_d | C) = \prod_{i=1}^d P(X_i | C)$$

lo que simplifica el cálculo de la probabilidad conjunta.

- (h) En un **SVM de margen suave**, si para un punto de datos $\vec{x}_i$ su multiplicador de Lagrange óptimo satisface $\alpha_i^* = C$, esto implica que el punto está necesariamente **mal clasificado**.

Respuesta: Falso.

- En un SVM de margen suave, si el multiplicador de Lagrange $\alpha_i^* = C$, el punto se encuentra en la **frontera del margen o fuera de él**.
- No necesariamente está mal clasificado; puede estar **exactamente en el margen** (violando ligeramente la condición de margen) o **mal clasificado**.
- Solo garantiza que el punto es **un soporte vector de tipo C**, usado para ajustar el margen.

- (i) El **Teorema de Aproximación Universal** establece que una red neuronal con una capa oculta no solo puede aproximar cualquier función continua, sino que también proporciona un método para encontrar los pesos óptimos para hacerlo.

Respuesta: Falso.

- El Teorema de Aproximación Universal garantiza que **existe** una configuración de pesos que permite a una red con una capa oculta aproximar cualquier función continua en un dominio compacto.
 - **No proporciona un método** para encontrar esos pesos; la optimización en la práctica depende de algoritmos de entrenamiento como backpropagation y puede ser difícil debido a mínimos locales y complejidad del espacio de parámetros.
- (j) El **estimador de Mínimos Cuadrados Ordinarios (MCO)** es un estimador insesgado incluso si los errores del modelo no siguen una distribución normal.

Respuesta: Verdadero.

- El estimador de Mínimos Cuadrados Ordinarios (MCO) es **insesgado** bajo las condiciones clásicas del modelo lineal (linealidad, independencia, homocedasticidad y media cero de los errores).
- La **normalidad de los errores** no es necesaria para la insesgadez; solo se requiere para realizar inferencias exactas (pruebas y intervalos de confianza) basadas en la distribución normal.

P4. Preguntas de aplicación (20 %)

- (a) Asuma que entrena un **modelo de clasificación SVM** usando un **kernel polinomial** $K(\mathbf{x}_i, \mathbf{x}_j) = (\langle \mathbf{x}_i, \mathbf{x}_j \rangle + c)^p$, para varios valores de $p \in \{1, 2, 3, 4\}$. Asuma que el parámetro c se escoge usando **validación-cruzada**. Se muestran tres posibles resultados de su error (**mean square error**) tanto de **entrenamiento** como **testeo**:

1.

p	1	2	3	4
Train error	0.36	0.31	0.24	0.17
Test error	0.25	0.21	0.18	0.23

2.

p	1	2	3	4
Train error	0.16	0.23	0.28	0.33
Test error	0.29	0.24	0.31	0.35

3.

p	1	2	3	4
Train error	0.24	0.20	0.18	0.13
Test error	0.32	0.26	0.23	0.28

(a)

¿Cuál resultado es **más realista** de encontrar en la práctica? Justifique.

Respuesta:

El resultado **más realista** es el 1.

- En la práctica, a medida que aumentamos el grado del kernel polinomial p , el modelo se vuelve más complejo y flexible. Esto típicamente reduce el **error de entrenamiento** de manera continua, como se observa en la fila "Train error" del resultado 1: $0.36 \rightarrow 0.17$. - El **error de test** inicialmente disminuye al aumentar p (de 0.25 a 0.18), indicando que un modelo más complejo se ajusta mejor a los datos y generaliza mejor. - Sin embargo, al aumentar demasiado la complejidad ($p = 4$), el error de test aumenta a 0.23, lo que indica **sobreajuste**: el modelo se ajusta demasiado al ruido del entrenamiento y su generalización empeora.

Los resultados 2 y 3 son menos realistas:

- En el resultado 2, el error de entrenamiento aumenta con la complejidad, lo cual contradice la teoría de que modelos más flexibles ajustan mejor los datos de entrenamiento. - En el resultado 3, el error de test disminuye hasta cierto punto, pero luego aumenta de manera irregular, y el sobreajuste se ve demasiado marcado sin una tendencia suave, lo cual es menos típico en práctica.

Por lo tanto, el patrón de disminución del error de entrenamiento combinado con un mínimo del error de test seguido de un ligero aumento (como en el resultado 1) refleja un comportamiento típico de **trade-off sesgo-varianza** en problemas reales.

- (b) Se aplican diferentes métodos de reducción de dimensionalidad a una nube de datos en forma de Rollo Suizo, los resultados se observan en la Figura 1. Explique a qué se deben las diferencias en las proyecciones obtenidas desde un punto de vista teórico. ¿Son directamente comparables las dimensiones del nuevo espacio? ¿Qué significa que dos puntos estén más cerca que otros en la proyección? ¿Depende lo anterior del método?




Figura 1: Diferentes métodos de reducción de dimensionalidad aplicados a una nube de datos en forma de Rollo Suizo.

Respuesta:

Las diferencias en las proyecciones se deben a cómo cada método preserva la estructura de los datos:

- **PCA:** Lineal, busca las direcciones de mayor varianza. No despliega correctamente un *manifold* no lineal (Rollo Suizo), preserva estructura global pero distorsiona distancias locales.
- **t-SNE:** No lineal, preserva estructura local mediante probabilidades de similitud. Muestra *clusters* claramente, pero distorsiona la estructura global.
- **UMAP:** No lineal, preserva estructura local y global mejor que t-SNE usando topología y geometría del *manifold*. Compromiso entre mantener vecinos y estructura global.

Comparabilidad de dimensiones:

- PCA: dimensiones ortogonales con significado de varianza.
- t-SNE/UMAP: dimensiones arbitrarias, solo útiles para visualización.

Significado de proximidad:

- PCA: similar en términos de varianza, puede no reflejar distancias intrínsecas.
- t-SNE: indica vecinos probables; proximidad global no significativa.
- UMAP: refleja conectividad en el *manifold*, distancia aproximada a la geodésica.

Dependencia del método: Sí, la interpretación de proximidad y dimensiones depende de la función objetivo y modelo de cada algoritmo.

- (c) Considere ahora la siguiente imagen que muestra 3 predicciones correspondientes a un mismo modelo en el que se ha variado un parámetro de su entrenamiento. Responda brevemente las preguntas.




Figura 2

1. ¿Qué **modelo** se está utilizando? Explique qué **parámetro del modelo varía** entre las tres estimaciones.

Respuesta:

- El modelo utilizado es probablemente un **Árbol de Decisión para Regresión** (o un modelo basado en árboles como un *Random Forest* o *Gradient Boosting*). Se identifica por la forma **escalonada** y **discontinua** de las predicciones 1 y 2.
- El parámetro que varía entre las tres estimaciones es la **complejidad del modelo** o **profundidad máxima del árbol** (`max_depth`) o el **número mínimo de muestras por hoja** (`min_samples_leaf`). La **Predicción 2** tiene una complejidad **alta** (muchas divisiones/poca regularización); la **Predicción 3** tiene una complejidad **mínima** (pocas divisiones/mucha regularización).

2. ¿Cual de las tres predicciones le parece la **más apropiada**?

Respuesta:

- La **Predicción 1** es la más apropiada.
- La **Predicción 2** presenta **sobreajuste** (*overfitting*) ya que sigue demasiado de cerca el ruido de los datos de entrenamiento.
- La **Predicción 3** presenta **subajuste** (*underfitting*) ya que es demasiado simple y no logra capturar la tendencia principal de los datos.
- La **Predicción 1** logra un **equilibrio sesgo-varianza** razonable, capturando la tendencia general sin memorizar el ruido.

3. ¿A qué corresponde el valor de la estimación para la **predicción 3**? ¿Cual de los tres elegiría para realizar una **poda de costo-complejidad**?

Respuesta:

- La Predicción 3 es una **línea horizontal constante**. Corresponde al valor **promedio** ($\bar{y}$) de todos los puntos de datos en el conjunto de entrenamiento.
- Esto ocurre cuando el árbol de decisión tiene la **complejidad mínima** posible (e.g., `max_depth = 1` o `min_samples_leaf = n`, donde n es el número total de datos), resultando en una única hoja que predice el promedio global.
- Para una poda costo-complejidad elegiría la **Predicción 2**.
- La **Poda de Costo-Complejidad** (*Cost-Complexity Pruning* o *Weakest Link Pruning*) se aplica sobre un árbol que ha sido entrenado hasta tener un **sobreajuste máximo** (como la Predicción 2), y luego se lo simplifica sistemáticamente para encontrar el mejor **sub-árbol** con base en la validación cruzada.

4. ¿Cual es el **error en el conjunto de entrenamiento** para la **predicción 2**?

Respuesta:

- El error de entrenamiento para la Predicción 2 (*Train Error*) es **menor** que el error de entrenamiento para la Predicción 1 y la Predicción 3.
- La Predicción 2 (sobreajuste) tiene el **mínimo error de entrenamiento** porque se ajusta estrechamente a cada punto.
- La Predicción 3 (subajuste) tiene el **máximo error de entrenamiento** porque es muy simple.
- La Predicción 1, al ser un modelo con complejidad intermedia, tendrá un error de entrenamiento que cumple con:

$$Error_{Train}(\text{Predicción 2}) < Error_{Train}(\text{Predicción 1}) < Error_{Train}(\text{Predicción 3})$$

- (d) Consideremos el problema de predecir la **cantidad de pasajeros en una aerolínea**. De forma incremental, se considerarán los siguientes mapas de características: 1) **polinomial**, 2) **polinomial + senoidal (oscilatorio)**, 3) **polinomial + senoidal (oscilatorio) + amplitud creciente**. Por lo tanto, denotando por x el tiempo e y la cantidad de pasajero, se considerará el siguiente **modelo final**:

$$y = \sum_{i=0}^3 \theta_i x^i + \sum_{i=1}^2 \alpha_i \exp(-\tau_i x^2) \cos(\omega_i(x - \psi_i)).$$

¿Qué se espera que capture cada uno de los **parámetros del modelo**? ¿Cómo **ajustaría** usted los **parámetros del modelo**? ¿Es la **solución de los parámetros única**? ¿Cómo afecta la elección de $\mathbf{x}_0$ en el modelo de optimización en la búsqueda de un **mínimo**? ¿Es el mínimo anterior **local o global**? Justifique.

Respuesta:

- **Interpretación de los parámetros:**

- θ_i ($i = 0, \dots, 3$): coeficientes del polinomio, capturan la **tendencia general** del número de pasajeros a lo largo del tiempo.
- $\alpha_i, \tau_i, \omega_i, \psi_i$ ($i = 1, 2$): parámetros de las componentes oscilatorias:
 - α_i : amplitud de la oscilación.
 - τ_i : decaimiento o concentración temporal de la oscilación.
 - ω_i : frecuencia de la oscilación (periodicidad).
 - ψ_i : fase o desplazamiento horizontal.

Estas capturan **patrones estacionales o cíclicos** y variaciones periódicas de la serie.

- **Ajuste de los parámetros (paso a paso):**

- Ajustar primero el polinomio (θ_i) para capturar la tendencia general de los datos.
- Agregar luego las componentes senoidales ($\alpha_i, \omega_i, \psi_i$) para modelar patrones periódicos sin afectar la tendencia.
- Finalmente, ajustar los parámetros de amplitud creciente o decaimiento (τ_i) para refinar la predicción y capturar variaciones estacionales progresivas.

Este enfoque incremental simplifica la optimización y reduce la probabilidad de quedar atrapado en mínimos locales subóptimos.

- **Unicidad de la solución:** La solución **no es única** debido a la naturaleza **no lineal y multimodal** de los términos oscilatorios. Diferentes combinaciones de $\alpha_i, \tau_i, \omega_i, \psi_i$ pueden producir ajustes similares al conjunto de datos.
- **Elección de x_0 (punto inicial):** La elección de un **punto inicial** en la optimización afecta fuertemente la convergencia hacia un mínimo **local**, especialmente dado que la función de costo es **no convexa**. Buenas estrategias incluyen inicialización basada en estimaciones preliminares (ej. FFT para frecuencia) o múltiples inicializaciones aleatorias.
- **Mínimos locales o globales:** Debido a la no linealidad y a la presencia de funciones oscilatorias, la función de costo tiene múltiples **mínimos locales**. Garantizar alcanzar el **mínimo global** es difícil; generalmente se obtiene un mínimo local que ofrece un buen ajuste práctico.