
Regresión Lineal

Aprendizaje de Máquinas, MDS (Primavera 2025)

Patricio Espinoza A.^{*1} Francisco Vásquez L.^{*12} Álvaro Márquez² Víctor Hernández M.³

Abstract

Este documento contiene la resolución de los problemas de la Tarea 1 del ramo Aprendizaje de Máquinas del Mágister en Ciencia de Datos de la Universidad de Chile.

1. Pregunta 1

Dada una función verdadera $g(z) = 2z^2$, para $z \in \mathbb{R}$. Con datos sin ruido $y = g(x) = 2x^2$ con $x \sim U(-1, 1)$, $\mathbb{E}[x] = 0$, $\mathbb{E}[x^2] = \frac{1}{3}$. Modelo lineal sin intercepto: $h(z) = \theta^T z$. Se entrena con un punto (x, y) , $x \neq 0$ (MCO).

Parte (a) Este modelo lineal tendrá un sesgo elevado ya que la función verdadera es de orden cuadrático $g(z) = 2z^2$, mientras que el modelo usa $h(z) = \theta^T z$. Además, aunque sea entrenado con mayor cantidad de datos, el modelo lineal nunca captará la curva de g .

Parte (b) Como $d = 1$ podemos escribir el modelo lineal como $h(x) = \theta x$. Dado que tenemos un solo dato, entonces MCO es tal que:

1. MCO $\mathcal{L}(\theta) = (y - \theta x)^2$, derivando respecto a θ .
2. $\frac{\partial \mathcal{L}}{\partial \theta} = \frac{\partial (y - \theta x)^2}{\partial \theta} = 2(y - \theta x)(-x) = -2x(y - \theta x)$
3. Condición Primer Orden para óptimo
 $-2x(y - \theta x) = 0 \Rightarrow y - \theta x = 0 \Rightarrow \hat{\theta} = \frac{y}{x}$
4. Dado que los datos son sin ruido $y = 2x^2$
 $\rightarrow \hat{\theta} = \frac{y}{x} \Rightarrow \hat{\theta} = \frac{2x^2}{x} = 2x$
5. El predictor queda como $h(z|x) = \hat{\theta}z = 2xz$ dado el $x \in \mathbb{R}$ usado para entrenar el modelo.

Parte (c) Definiendo el sesgo como el Bias, tenemos que:

1. $Bias(z) = \mathbb{E}_x[2xz] - g(z)$
2. Por linealidad, $\mathbb{E}_x[2xz] = 2z\mathbb{E}_x[x]$
3. Por enunciado, $\mathbb{E}_x[x] = 0 \Rightarrow 2z\mathbb{E}_x[x] = 0$
4. Dada $g(z) = 2z^2 \Rightarrow Bias(z) = -2z^2$

Parte (d) Definiendo la varianza, tenemos que:

1. $Var_x(h(z|x)) = Var_x(2xz)$
2. Por linealidad, $Var_x(2xz) = (2z)^2 Var_x(x)$
3. Usando la definición $Var(x) = \mathbb{E}[x^2] - \mathbb{E}[x]^2$
Por enunciado, $\Rightarrow Var(x) = (\frac{1}{3} - 0^2) = \frac{1}{3}$

4. Retomando el punto 2

$$Var_x(h(z|x)) = (2z)^2 \frac{1}{3} = \frac{4}{3}z^2$$

Parte (e) Dado que tenemos datos sin ruido, entonces:

1. $E(h, z) = Bias(z)^2 + Var(z)$
2. De las partes anteriores tenemos entonces que
 $\rightarrow E(h, z) = (-2z^2)^2 + \frac{4}{3}z^2 = 4z^2 + \frac{4}{3}z^2$
3. Para $z = 1$ se tendrá que

$$E(h, 1) = 4(1)^2 + \frac{4}{3}(1)^2 = \frac{16}{3} \approx 5,3$$

Parte (f) El problema de la selección de características es que el modelo planteado $h(z) = \theta^T z$ es lineal, mientras que la función verdadera es cuadrática $g(z) = 2z^2$. Esto significa que las características de la función verdadera no podrán ser representadas correctamente.

Para solucionar este problema, se pueden añadir nuevas características tal que: $h(z) = \theta_1^T z + \theta_2^T z^2$. Luego, con $\theta_1^T = 0$ y $\theta_2^T = 2$ tenemos que al aumentar la complejidad del modelo, disminuimos el sesgo de este, y dado que los puntos están libres de ruido, no aumentará la varianza.

Parte (g) Se podría modelar la energía de un resorte elástico $E = \frac{1}{2}kx^2$. La Regresión Lineal puede aportar en cuanto a simplificar la interpretabilidad del problema, por ejemplo, explicando sencillamente si la relación entre variables es directa o inversamente dependiente sin necesitar un modelo más complejo.

Por otra parte, la elección de un modelo lineal, menos preciso pero más interpretable o explicable, podría servir en un contexto de enseñanza de energía elástica a estudiantes de educación básica con pocos conocimientos profundos sobre funciones cuadráticas.

2. Pregunta 2

Dado un modelo $Y = \beta_0 + \beta^T X + \epsilon$, $\epsilon \sim \mathcal{N}(0, \sigma^2)$

Con $\beta = (\beta_1, \dots, \beta_p)^T$ y σ^2 conocido. Nos interesa la estimación Bayesiana de los parámetros $\theta = (\beta_1, \dots, \beta_p)$

Suponemos que la distribución X no depende de θ .

Sean $(x_i, y_i)_{1 \leq i \leq N}$ datos

Parte (a) Para demostrar que el máximo a posteriori (MAP) con un prior uniforme equivale al estimador de máxima verosimilitud (MLE) tenemos que:

1. X es la matriz $N \times p$ (cada fila x_i^T), $\beta \in \mathbb{R}^p$ y β_0 el intercepto.

Suponiendo prior impropio uniforme sobre (β_0, β) : $p(\beta_0, \beta) \propto 1$

1. Tendremos que la verosimilitud de los datos (densidad de estos dada $\theta = (\beta_0, \beta)$ es:

$$p(y|X, \beta_0, \beta) = (2\pi\sigma^2)^{-\frac{N}{2}} \exp\left(-\frac{1}{2\sigma^2} \|y - \beta_0 \mathbf{1} - X\beta\|^2\right)$$

2. El posterior es proporcional a prior $\times$ verosimilitud. Con prior uniforme:

$$p(\beta_0, \beta|y, X) \propto p(y|X, \beta_0, \beta)$$

3. Luego, tenemos que maximizar MAP es equivalente a maximizar la verosimilitud:

$$\hat{\theta}_{MAP} = \operatorname{argmax}_{\beta_0, \beta} p(\beta_0, \beta|y, X) = \operatorname{argmin}_{\beta_0, \beta} \|y - \beta_0 \mathbf{1} - X\beta\|^2$$

4. La solución de este problema es el estimador de mínimos cuadrados. Por tanto, para prior uniforme:

$$\Rightarrow \hat{\theta}_{MAP} = \hat{\theta}_{MLE} = \hat{\theta}_{OLS}$$

Parte (b)

Suponiendo un prior gaussiano independiente en los coeficientes, sin penalizar al intercepto:

$$\beta \sim \mathcal{N}(0, \tau^2 I_p), p\beta_0 \propto 1$$

1. El posterior (hasta constante) será:

$$p(\beta_0, \beta|y) \propto \exp\left(-\frac{1}{2\sigma^2} \|y - \beta_0 \mathbf{1} - X\beta\|^2\right) \exp\left(-\frac{1}{2\tau^2} \|\beta\|^2\right)$$

2. Tomando el negativo del log-posteriori y omitiendo ctes:

$$\mathcal{L}(\beta_0, \beta) = \frac{1}{2\sigma^2} \|y - \beta_0 \mathbf{1} - X\beta\|^2 + \frac{1}{2\tau^2} \|\beta\|^2$$

3. Resolviendo para β_0 con CPO

$$\frac{\partial \mathcal{L}}{\partial \beta_0} = \frac{1}{\sigma^2} \mathbf{1}^T (\beta_0 \mathbf{1} + X\beta - y) = 0$$

$$\Rightarrow N\beta_0 + \mathbf{1}^T X\beta - \mathbf{1}^T y = 0 \Rightarrow \beta_0 = \bar{y} - \bar{x}^T \beta$$

$$\text{con } \bar{y} = \frac{1}{N} \mathbf{1}^T y \text{ y } \bar{x} = \frac{1}{N} \mathbf{1}^T X$$

4. Luego, centramos los datos tal que:

$$y_c = y - \bar{y} \mathbf{1} \text{ y } X_c = X - \mathbf{1} \bar{x}^T$$

Además, sustituir β_0 en $\mathcal{L}$ simplifica a minimizar sobre β :

$$\tilde{\mathcal{L}}(\beta) = \frac{1}{2\sigma^2} \|y_c - X_c \beta\|^2 + \frac{1}{2\tau^2} \|\beta\|^2$$

5. Derivando respecto a β :

$$\nabla_{\beta} \tilde{\mathcal{L}}(\beta) = \frac{1}{\sigma^2} X_c^T (X_c \beta - y_c) + \frac{1}{\tau^2} \beta = 0$$

$$\Rightarrow (X_c^T X_c + \lambda I_p) \beta = X_c^T y_c, \text{ donde } \lambda := \frac{\sigma^2}{\tau^2}$$

6. Luego, la solución al MAP es:

$$\hat{\beta}_{MAP} = (X_c^T X_c + \lambda I_p)^{-1} X_c^T y_c \text{ con } \hat{\beta}_0 = \bar{y} - \bar{x}^T \hat{\beta}_{MAP}$$

7. La solución obtenida corresponde a Ridge (L2) con parámetro $\lambda = \sigma^2 / \tau^2$

Parte (c) Usando $\rho = \lambda = \sigma^2 / \tau^2$

1. Para $\tau \rightarrow \infty$ (prior difuso) tenemos que $\lambda \rightarrow 0$, entonces:

$\hat{\beta} \rightarrow (X_c^T X_c)^{-1} X_c^T y_c$ Esto significa que la solución MAP tiende a Mínimos Cuadrados Ordinarios, además, significa que la información proviene solo de los datos al no hacer regularización

2. Para $\tau \rightarrow 0$ (prior concentrado en 0) $\Rightarrow \lambda \rightarrow +\infty$

Por tanto, la matriz $(X_c^T X_c + \lambda I)$ es dominada por λI

$$\Rightarrow \hat{\beta} \approx \frac{1}{\lambda} X_c^T y_c \rightarrow 0$$

Esto significa que el prior fuerza los coeficientes hacia 0, colapsando el modelo hacia el intercepto $\hat{\beta}_0 \approx \bar{y}$. Esto significa que los coeficientes solo pueden ser grandes si los datos aportan evidencia muy fuerte que contrarreste al prior.

Ambos casos muestran los extremos entre *prior* y *regularización*. Un prior más informativo (τ pequeño) equivale a mayor penalización (mayor λ), y mayor regularización.

Parte (d) Veremos $\mathbb{E}[\hat{\beta}_{MAP}]$ para el modelo verdadero, y en que caso es igual a el verdadero vector de parámetros β^* .

1. Suponiendo entonces que el modelo centrado verdadero es:

$$y_c = X_c \beta^* + \epsilon, \mathbb{E}[\epsilon] = 0, \operatorname{Var}(\epsilon) = \sigma^2 I, \text{ usando } X_c \text{ fijo:}$$

$$\Rightarrow \hat{\beta}_{MAP} = (X_c^T X_c + \lambda I)^{-1} X_c^T y_c$$

2. Aplicando la esperanza

$$\Rightarrow \mathbb{E}[\hat{\beta}_{MAP}] = (X_c^T X_c + \lambda I)^{-1} X_c^T \mathbb{E}[y_c]$$

$$\Rightarrow \mathbb{E}[\hat{\beta}_{MAP}] = (X_c^T X_c + \lambda I)^{-1} X_c^T X_c \beta^*$$

3. Definiendo la matriz de encogimiento tal que:

$$\mathcal{A}(\lambda) := (X_c^T X_c + \lambda I)^{-1} X_c^T X_c$$

$$\text{Entonces } \mathbb{E}[\hat{\beta}_{MAP}] = \mathcal{A}(\lambda) \beta^*$$

3.1 Si $\rho = \lambda = 0$ entonces $\mathcal{A}(0) = I_p$ (si $X_c^T X_c$ es invertible), y por tanto $\mathbb{E}[\hat{\beta}_{MAP}] = \beta^*$

$\Rightarrow$ *Insesgado*

3.2 Si $\rho = \lambda > 0$ entonces $\mathcal{A}(\lambda) \neq I_p$, y por tanto $\mathbb{E}[\hat{\beta}_{MAP}] \neq \beta^*$

$\Rightarrow$ *Sesgado*

4. Escribiendo el sesgo de forma explícita:

$$\Rightarrow \text{Bias}(\hat{\beta}_{MAP}) := \mathbb{E}[\hat{\beta}_{MAP}] - \beta^*$$

$$\Rightarrow \text{Bias}(\hat{\beta}_{MAP}) = ((X_c^T X_c + \lambda I)^{-1} X_c^T X_c - I) \beta^*$$

$$\Rightarrow \text{Bias}(\hat{\beta}_{MAP}) = -\lambda (X_c^T X_c + \lambda I)^{-1} \beta^*$$

A partir de esto podemos concluir que $\text{Bias} = 0$ para todo β^* solo si $\rho = \lambda = 0$.

De forma práctica, $\rho = 0$ equivale a un prior de varianza infinita no informativo, lo que recupera MCO. Esto puede ser útil si se dispone de muchos datos y el ruido es bajo, ya que en ese caso no se necesita regularización. En otros escenarios (pocos datos, alto ruido o multicolinealidad), suele preferirse un cierto sesgo a cambio de una menor varianza, lo que mejora la estabilidad y la generalización.

3. Pregunta 3

Parte a $y_{sr} = \theta_0 + \theta_1 x_{vp} + \theta_2 x_{hv} + \theta_3 x_{lr} + \epsilon$

x_{vp} corresponde a la columna `verified_purchase`

x_{hv} corresponde a la columna `helpful_vote`

x_{lr} corresponde a la columna `length_of_review` aplicada a los textos mediante `str.split.apply(len)`

Los parámetros del modelo son $\theta_0, \theta_1, \theta_2, \theta_3$.

El ruido corresponde a $\epsilon \sim \mathcal{N}(0, \sigma^2)$

Parte b

En el 50% del conjunto de datos trabajado se observa que la distribución de calificaciones está fuertemente desbalanceada (Tabla [1] y Figura [1]). En particular, la calificación 5 concentra un 84% de las observaciones, mientras que la segunda categoría más frecuente es la calificación 1 con solo un 8%.

La media del rating es 4.55 y la varianza 1.34, lo que confirma una fuerte concentración de los datos en el extremo alto de la escala de calificaciones.

Este desbalance implica que un modelo de regresión lineal difícilmente pueda explicar bien la variabilidad de la respuesta, ya que la mayor parte de la señal está concentrada en un solo valor. Un predictor simple (ej., siempre predecir 5) ya obtendría un RMSE bajo. Por ello, aunque

las métricas como MSE o RMSE puedan resultar pequeñas debido a la concentración, no necesariamente reflejarán un buen ajuste. En particular, el R^2 puede ser bajo porque el modelo no captura variabilidad significativa más allá de la media.

En síntesis, aunque un modelo lineal pueda mostrar errores pequeños en términos absolutos, no se espera que tenga un buen ajuste explicativo debido al fuerte desbalance de las calificaciones.

Parte c

Al realizar una división 80/20 para train/test, y evaluar la Regresión Lineal con distintas métricas se obtuvieron los parámetros asociados a cada columna (indicados en la parte (a)) (Tabla [2]). En particular:

θ_0 : Representa el nivel base del rating esperado cuando todas las otras variables predictoras son 0. Esto significa que, si no hay información sobre la compra verificada, votos o reseña, la predicción del modelo se centrará en torno a las 4.2 estrellas.

θ_1 : Indica que una reseña con compra verificada tiende a recibir, en promedio, 0.62 estrellas más que una reseña sin compra verificada, manteniendo las demás variables constantes.

θ_2 : Indica que cada voto adicional se asocia con un cambio de -0.0003 en el rating. Como su magnitud es tan pequeña, se puede concluir que esta variable no tiene un poder explicativo relevante para la predicción total del modelo.

θ_3 : Refleja que por cada palabra adicional en la reseña, el rating disminuye en promedio 0.015 estrellas. Aunque el efecto individual es pequeño, para reseñas largas podría acumularse en reducciones perceptibles en la predicción. Además esto indica que cuando se dejan reseñas, generalmente parecieran estar asociadas con un menor rating.

Por otra parte, a partir de los valores de RMSE, MSE, MAE y R^2 en train y test (Tabla [2]) se pueden observar que:

El modelo presenta un R^2 bajo (≈ 0.12 en ambos conjuntos) lo que indica que solo explica alrededor de un 12% de la variabilidad en la calificación por estrellas. Esto es un resultado esperable dado que la percepción de calidad en reseñas depende en gran medida de factores subjetivos y no completamente observados en las variables consideradas (en particular x_{hv}).

Por otra parte, las métricas de error (RMSE y MAE) resultan bastante similares entre los conjuntos de entrenamiento y prueba, lo que indica que el modelo no presenta sobreajuste y mantiene una capacidad de generalización estable. El valor de RMSE cercano a 1 sugiere que, en promedio, el modelo se equivoca aproximadamente en una estrella al predecir la calificación. A su vez, un MAE cercano a 0.66 implica que

el error promedio absoluto equivale a dos tercios de estrella en la escala de rating.

Finalmente, la variable con mayor efecto fue la compra verificada (x_{vp}), es decir, la confianza en la reseña influye claramente en el puntaje. En contraste, los votos útiles y la longitud de la reseña tienen impacto marginal y negativo, indicando que no necesariamente se correlacionan con la valoración otorgada.

En síntesis, el modelo lineal ajusta de forma limitada la relación entre las variables disponibles y el rating, siendo útil la compra verificada, pero con poca capacidad explicativa para el resto de los predictores.

Parte d

A partir del gráfico (Figura [3]) se observa que la norma de los parámetros de Ridge y Lasso disminuye conforme aumenta ρ . En particular, Lasso presenta una caída mucho más rápida, llevando varios coeficientes hacia cero cuando $\rho \approx 10^{-3}$. En contraste, Ridge mantiene la norma casi constante hasta valores cercanos a $\rho \approx 10^1$ y luego decae de forma más suave. El modelo MCO, al no tener regularización, se mantiene constante con una norma cercana a 0.6.

Lasso (penalización L1) fuerza la selección de un subconjunto de variables, eliminando aquellas que aportan poca información o que son redundantes. Ridge, en cambio, encoge todos los coeficientes de manera proporcional pero rara vez los anula exactamente. En particular, las características que no aportaron tanto fueron `helpful_vote` y `length_of_review` en base a los resultados previos (Tabla [2]).

A partir del gráfico (Figura [2]) se observa que en los tres modelos el error cuadrático medio (ECM) es mayor en el conjunto de prueba que en el de entrenamiento, lo que refleja el compromiso sesgo-varianza entre ambos conjuntos.

En particular, el MCO obtiene un $ECM \approx 1.22$, mientras que Ridge logra valores similares, manteniéndose alrededor del mismo nivel que MCO. Lasso en cambio muestra un comportamiento escalonado, su ECM comienza a crecer al aumentar ρ , superando 1.35 desde $\rho \approx 10^1$, lo que refleja un exceso de regularización (subajuste).

En síntesis, Ridge logra un encogimiento suave que estabiliza los coeficientes sin aumentar demasiado el error, mientras que Lasso introduce selección de variables, lo cual puede ser útil en presencia de multicolinealidad. Sin embargo, en este dataset con pocas variables, la capacidad de Lasso para forzar coeficientes a cero no aporta tanto y, con valores de ρ muy grandes, termina aumentando el error por exceso de regularización.

Parte e

A partir del gráfico de correlaciones entre variables predictoras (Figura [4]) se observa que los valores son bajos. Las correlaciones más altas alcanzan solo 0.16 y -0.18. Esto permite concluir que no existe multicolinealidad significativa entre las variables del dataset.

Cuando sí existe multicolinealidad fuerte, los estimadores de MCO presentan alta varianza, lo que implica que ante pequeñas variaciones en los datos los coeficientes pueden cambiar drásticamente, dificultando su interpretación.

Ridge mitiga este problema al añadir ρI a $x^T X$, mejorando el condicionamiento de la matriz, y reduciendo así la varianza de los estimadores, que a su vez, estabiliza los coeficientes frente a la multicolinealidad.

Por otra parte, Lasso además de encoger los coeficientes puede llevarlos directamente a 0, seleccionando así un subconjunto de variables específico, eliminando aquellas redundantes. Es decir, ante variables predictoras altamente correlacionadas, Lasso solo se queda con una de ellas, mitigando así la multicolinealidad.

Parte f

A partir de la Tabla 3 se observa que las métricas de error (RMSE, MSE, MAE y R^2) se mantienen iguales al caso no escalado (Parte b). Esto ocurre porque solo se transformaron las variables predictoras X , mientras que las predicciones $\hat{y}$ y los valores reales y permanecieron en la misma escala. Por lo tanto, las métricas son plenamente comparables.

En cuanto a los coeficientes del modelo, antes estaban condicionados por la escala de cada variable. Tras el escalado, todas presentan media 0 y varianza 1, lo que permite comparar directamente las magnitudes de los coeficientes y asegura que tanto Ridge como Lasso penalicen de forma equitativa. En particular, θ_0 aumentó, θ_1 disminuyó de 0.61 a 0.15, θ_2 creció ligeramente pero sigue siendo marginal (-0.0076), mientras que θ_3 se incrementó notablemente (de -0.0146 a -0.3467), reflejando que antes estaba condicionado por la magnitud de la longitud de las reseñas.

Finalmente, los gráficos (Figuras [5] y [6]) muestran que el ECM para Ridge y Lasso parte con valores similares en entrenamiento y prueba. Ridge mantiene un comportamiento estable respecto al caso previo, mientras que Lasso pasa de dos reducciones escalonadas a una sola, gracias al escalamiento que igualó la influencia de las variables. En la norma de los parámetros, tanto Ridge como Lasso exhiben una disminución más suave conforme aumenta ρ . Esto se debe a que, al estar todas las variables en la misma escala, los coeficientes se contraen de forma más balanceada, evitando que unos decrezcan mucho más rápido que otros, como ocurría antes del escalado.

Parte g

El número del mes y el año pueden servir para capturar tendencias temporales en los ratings, dado que pueden existir patrones asociados a fechas especiales. Sin embargo, estas tendencias no necesariamente se repiten en el tiempo y podrían inducir sesgos estacionales que el modelo no generalice bien en otros periodos. Desde un punto de vista teórico y estadístico, su aporte es limitado, ya que no están directamente relacionados con la calidad del producto ni con la valoración subjetiva del usuario.

Los resultados obtenidos (Tabla [4]) muestran que, para un mismo modelo, las diferencias entre las métricas de entrenamiento y prueba son leves, lo que indica que el modelo no está sobreajustado. Al comparar los modelos en el conjunto de prueba, se observa que el menor RMSE, MSE (ECM) y MAE corresponden a MCO, mientras que el menor R^2 lo obtuvo Lasso, muy cercano a ElasticNet. Esto se debe a que al regularizar por Lasso y ElasticNet se penalizan fuertemente los nuevos coeficientes añadidos, reduciendo la capacidad explicativa del modelo al forzar a algunos parámetros hacia cero, afectando negativamente las métricas en este caso.

Respecto a los resultados previos (Tabla [3]) para MCO, al incluir las variables de mes y año, el modelo MCO logra una mejora ligera en el ajuste, el RMSE y el MAE se reducen en ambos conjuntos, mientras que el R^2 aumenta. Esto significa que, aunque el efecto de las variables temporales es acotado, sí aportan un pequeño poder explicativo adicional.

Las principales limitaciones de incluir estas variables son que su efecto puede ser falso, reflejando patrones de estacionalidad o promociones específicas que no necesariamente se repiten. Además, pueden inducir una falsa confianza en tendencias temporales que no tienen relación con el rating.

Finalmente, se observa que (Tabla [3]), en todos los modelos, las métricas de error (RMSE, MSE y MAE) aumentan levemente en el conjunto de prueba respecto al de entrenamiento, mientras que el R^2 disminuye, lo que indica un ligero aumento del sesgo en generalización, dada la complejidad añadida por las nuevas variables.

Parte h

El modelo más recomendado en este contexto es Ridge. Si bien los resultados de MCO mostraron métricas mejores, Ridge ofrece una mayor estabilidad en los coeficientes y un mejor control frente a ruido en los datos, lo cual es relevante dado que algunas variables presentan bajo poder explicativo. Además, Ridge mantiene todos los predictores en el modelo, lo que evita perder información potencialmente útil, a diferencia de Lasso que tiende a anular parámetros. Por estas razones, resulta una opción más robusta y confiable para generalizar.

La métrica estadística más robusta es el MAE. A diferencia

del RMSE/MSE, que penalizan fuertemente los errores al elevarlos al cuadrado, el MAE otorga un peso proporcional a cada error y es menos sensible a outliers. Esto es útil en este dataset, donde el rating de los usuarios puede verse afectado por factores subjetivos y generar outliers.

No se espera que la RL Bayesiana mejore significativamente los resultados en cuanto a métricas (RMSE, MAE, R^2), dado que el bajo poder explicativo se debe principalmente a que las variables predictoras no capturan la complejidad detrás del rating. Sin embargo, sí entrega ventajas como permitir cuantificar la incertidumbre en los parámetros mediante distribuciones posteriores, otorgando interpretaciones probabilísticas y mejoras en la regularización vía priors.

Desde un punto de vista bayesiano, el problema puede ser abordado definiendo priors adecuados para los coeficientes de acuerdo con el conocimiento previo sobre las variables. Por ejemplo, un prior más restrictivo para `helpful_vote` dada su baja relevancia, y uno más laxo para `verified_purchase` que mostró un mayor impacto en la calificación. De esta forma, el modelo no solo ajustaría los datos observados, sino que también incorporaría información previa y manejaría explícitamente la incertidumbre asociada a las estimaciones.

Parte i

A partir del gráfico de residuos versus predicciones (Figura 7) se observa que los residuos no se distribuyen de manera aleatoria alrededor de cero, sino que muestran patrones y franjas concentradas en ciertos valores de la predicción. Indicando la presencia de heterocedasticidad, es decir, la varianza de los errores no es constante a lo largo de las predicciones.


En los gráficos de dispersión entre cada variable predictora y la variable dependiente (Figuras 8, 9, 10) no se aprecia una relación lineal clara. La variable `verified_purchase` es binaria (0/1), por lo que no muestra una tendencia continua con el rating. En tanto, `helpful_vote` y `length_of_review` presentan dispersión en todos los niveles de rating, lo que se traduce en líneas horizontales sin evidencia de linealidad.

Por último, el gráfico Q-Q de los residuos (Figura 11) muestra que los cuantiles empíricos se desvían de la línea teórica de la normal, lo que sugiere que los errores no siguen una distribución normal.

Los tres análisis permiten concluir que varios de los supuestos de la RL no se cumplen: no hay homocedasticidad, no hay linealidad clara entre predictores y respuesta, y los errores no siguen una distribución normal. Indicando que el modelo lineal ajustado tiene una validez estadística limitada y que las métricas obtenidas deben interpretarse con precaución, ya que inferencias basadas en supuestos clásicos como los intervalos de confianza pueden no ser confiables en este contexto.

A. Anexo**B. Pregunta 3****B.1. Parte b***Table 1.* Distribución de ratings con conteos, proporciones y estadísticos.

RATING	CONTEO	PORCENTAJE
1	6196	8.13%
2	938	1.23%
3	1630	2.14%
4	3352	4.40%
5	64089	84.10%
MEDIA		4.55
VARIANZA		1.34

*Figure 1.* Histograma de las calificaciones del conjunto total de datos.**B.2. Parte c***Table 2.* Resultados de la regresión lineal (MCO) con división 80/20 en train/test.

	RMSE	MSE	MAE	R^2
TRAIN (80%)	1.0789	1.1640	0.6642	0.1242
TEST (20%)	1.1051	1.2212	0.6786	0.1164
PARÁMETROS	$\hat{\theta}_0$	$\hat{\theta}_1(x_{vp})$	$\hat{\theta}_2(x_{hv})$	$\hat{\theta}_3(x_{lr})$
VALORES	4.2110	0.6165	-0.0003	-0.0146

B.3. Parte d




Figure 2. Error cuadrático medio (ECM/MSE) versus ρ para Training y Testing.




Figure 3. Norma de los parámetros versus ρ para los modelos.

B.4. Parte e






Figure 4. Matriz de correlación entre variables predictoras.

B.5. Parte f

Table 3. Resultados de la regresión lineal (MCO) con división 80/20 en train/test , aplicando un escalado de datos.

	RMSE	MSE	MAE	R^2
TRAIN (80%)	1.0789	1.1640	0.6642	0.1242
TEST (20%)	1.1051	1.2212	0.6786	0.1164
PARÁMETROS	$\hat{\theta}_0$	$\hat{\theta}_1(x_{vp})$	$\hat{\theta}_2(x_{hv})$	$\hat{\theta}_3(x_{lr})$
VALORES	4.5546	0.1561	-0.0076	-0.3467

Figure 5. Error cuadrático medio (ECM/MSE) versus ρ para Train-ing y Testing con datos escalados.Figure 6. Norma de los parámetros versus ρ para los modelos con datos escalados.

B.6. Parte g

Table 4. Métricas de desempeño para diferentes modelos y conjuntos (Train/Test).

MODELO / CONJUNTO	RMSE	MSE	MAE	R^2
MCO-TRAIN	1.0673	1.1392	0.6550	0.1428
MCO-TEST	1.0929	1.1944	0.6695	0.1358
RIDGE-TRAIN	1.0673	1.1392	0.6550	0.1428
RIDGE-TEST	1.0929	1.1944	0.6695	0.1358
LASSO-TRAIN	1.0905	1.1893	0.6830	0.1052
LASSO-TEST	1.1153	1.2439	0.6971	0.1000
ELASTICNET-TRAIN	1.0899	1.1880	0.6794	0.1062
ELASTICNET-TEST	1.1152	1.2437	0.6935	0.1002

B.7. Parte i




Figure 7. Residuos versus predicciones para validar la homocedasticidad del modelo.




Figure 8. Dispersión de la compra verificada versus el rating.




Figure 9. Dispersión del voto de ayuda versus el rating.




Figure 10. Dispersión del largo de la review versus el rating.




Figure 11. Q-Q plot para evaluar normalidad de los errores, los puntos azules son los residuos, mientras que la linea roja es la teórica.