
Modelos de Clasificación, uso de AIC y BIC

Aprendizaje de Máquinas, MDS (Primavera 2025)

Patricio Espinoza A.^{* 1} Francisco Vásquez L.^{* 1 2} Álvaro Márquez² Víctor Hernández M.³

Abstract

Este documento contiene la resolución de los problemas de la Tarea 4 del ramo Aprendizaje de Máquinas del Mágister en Ciencia de Datos de la Universidad de Chile.

1. Pregunta 1

Parte (a)

El dataset consiste de las variables numéricas Age, RestingBP, Cholesterol, MaxHR y Oldpeak, Y de las variables categóricas Sex, ChestPainType, FastingBS (0/1), RestingECG, ExerciseAngina y ST_Slope. Por último, el objetivo de predicción es la variable 'HeartDisease' con valores 0 o 1.

De las Figuras 2 y 3 podemos ver que al menos una parte de las curvas de distribución de las variables numéricas tiende a seguir una distribución normal. En particular Age, RestingBP y MaxHR cumplen esto. Para Cholesterol si se omiten aquellos con 0 también se cumple, y lo mismo sucede para Oldpeak. FastingBS y HeartDisease realmente son categóricas representadas de forma binaria (0/1).

En cuanto al resto de variables categóricas, hay mayor tendencia de personas masculinas, de dolor de pecho ASY, y que en general para RestingECG, ExerciseAngina y ST_Slope predomina cierta Clase de cada categoría, mostrando un desbalance entre estas.

En cuanto a las estadísticas descriptivas, podemos ver de la Tabla 2 que la edad suele estar concentrada en un grupo de 'Adultos Mayores' y 'Tercera Edad'. También llama la atención que la desviación estándar de 'Cholesterol' es alta, muy probablemente debido a la gran concentración de ceros.

Por otra parte, de la Tabla 1 se puede observar que ninguna variable posee nulos.

Finalmente, de la Figura 1 podemos ver que se tienen alrededor de 100 casos más de la Clase 1 que de la Clase 0 para la variable objetivo, indicando un pequeño desbalanceo.

Respecto a la preparación de datos, se realizó una división de entrenamiento (80%) y prueba (20%). A las variables numéricas (no dummies) se les realizó un escalamiento ya que LDA y SVM son sensibles a la magnitud de las características (variables).

Parte (b)

Al entrenar un modelo de Regresión Logística con los hiperparametros `max_iter=5000`, `solver='saga'`, `class_weight='balanced'`, `penalty='l1'`, `C=1.0` se obtuvieron las matrices de la Tabla 3, donde destaca que pese a que en el conjunto de entrenamiento hubiese una cantidad considerable de Falsos Positivos y Falsos Negativos, los cuales disminuyeron considerablemente en el conjunto de prueba.

Por otra parte, de las Tablas 4 y 5 podemos ver que en ambos conjuntos, entrenamiento y prueba respectivamente, se obtuvieron buenas métricas para precision (0.85 vs 0.90), recall (0.85 vs 0.90) y F1-score (0.85 vs 0.90), resultando en un leve mejor rendimiento en el conjunto de prueba (accuracy de 0.90) que en el de entrenamiento (accuracy de 0.86). Esto se puede atribuir al uso de penalización Lasso, permitiendo una mejor capacidad de generalización.

Parte (c)

AIC permite elegir el modelo con mejor capacidad predictiva (minimiza la pérdida de información), independiente de si es más o menos complejo. Es preferible un modelo con menor AIC.

Por otra parte, BIC elige el modelo más simple (parsimonioso) que explique correctamente los datos. Es preferible un modelo con menor BIC.

En cuanto a las formulas de cada uno tenemos que:

$$AIC = -2\hat{l} + 2d \quad BIC = -2\hat{l} + d \cdot \ln(N)$$

Con los siguientes términos:

$\hat{l}$ es la log-verosimilitud maximizada sobre el conjunto de entrenamiento. Esto esta relacionado a que tan bien está ajustado el modelo a los datos. (Más negativo peor ajuste)

d es el número de parámetros estimados. Un número mayor implica un modelo más complejo (no necesariamente

mejor).

N es el tamaño de la muestra.

AIC penaliza la complejidad linealmente por número de parámetros d , al igual que la máxima log-verosimilitud. Este se relaciona con minimizar la pérdida de información (aprox. la divergencia KL). Por otro lado, BIC penaliza más fuerte la complejidad que AIC ya que se linkean los parámetros con N . BIC tiende a favorecer modelos más parsimoniosos (asume un prior bayesiano).

Parte (d)

Los tres modelos que compararemos son:

- M1: todas las variables (modelo completo).
- M2: Elegir automáticamente con chi-cuadrado las 6 mejores variables al medir la dependencia entre cada variable y la clase objetivo.
- M3: Elegido usando regularización Lasso (L1) con $C=0.1$.

Esto resultó en los subconjuntos de variables mostrados en la Tabla 6, los cuales se entrenaron con los hiperparámetros presentes en la Tabla 7.

Los resultados obtenidos presentes en la Tabla 8 permiten ver que modelo es el mejor por cada criterio. M1 es el modelo con la log-verosimilitud (-241) menos negativa y por tanto es el que mejor se ajusta a los datos, seguido de cerca por M3 (-245) y posteriormente por M2 (-268).

Un d menor implica un modelo más simple/parsimonioso, el orden de más simple a más complejo es $M2 \rightarrow M3 \rightarrow M1$.

En cuanto a AIC el mejor modelo fue M3 con 513.58, seguido de M1 con 515.76 y M2 con 551.05. Y respecto a BIC el mejor fue M3 con 564.17, seguido de M2 con 583.24 y M1 con 589.34. Finalmente, en cuanto a F1-Promedio obtenido de CV se obtuvo $M3 (0.879) > M1 (0.858) > M2 (0.856)$.

Los criterios resultaron consistentes entre sí, mostrando su relación con la log-verosimilitud y d . Además, se puede concluir que el modelo M3 fue el que obtuvo mejores métricas en general.

Parte (e)

Para el modelo LDA se utilizaron las variables presentes en la Tabla 9, a partir del cual se obtuvo la Matriz de Confusión de la Tabla 10 donde se puede apreciar una cantidad muy pequeña de Falsos Negativos (7) y Falsos Positivos (13) indicando un buen desempeño. Al pasar a las métricas específicas presentes en la Tabla 11 podemos ver que el modelo tuvo un desempeño levemente menor al de regresión logística con todas las variables (Tabla 5), en particular al comparar el Recall de la clase 0.

Por otra parte, de la Tabla 12 podemos ver que se obtuvo una log-verosimilitud mucho más negativa (-773.88 generativa y -256.84 discriminativa) que M1 y M3, implicando un peor ajuste bruto a los datos. Asimismo obtuvo muchos más parámetros (Generativo $d=151$) que la regresión logística debido al uso de todas las variables y el término cuadrático presente en:

$$d = (K - 1) + K \times M + \frac{M(M + 1)}{2}$$

para K clases y M features

En los resultados de la Tabla 12 podemos ver el enfoque generativo (densidad conjunta) y discriminativo (verosimilitud condicional). En particular en cuanto a AIC y BIC, se puede usar el del enfoque discriminativo (predicciones) para comparar con las Regresiones Logísticas. En este se obtuvo una métrica $AIC=545.67$ mayor que M1 y M3, pero menor que M2, indicando que es un modelo que se ajusta peor a los datos. Por otro lado, la métrica BIC obtenida fue de 619.25, la cual fue la más alta respecto a las obtenidas con Regresiones Logísticas, indicando que este modelo es claramente más complejo, y que basado en este criterio, se preferiría una RL.

Parte (f)

Para SVM se utilizó el mismo conjunto de variables de la Parte 'e' presente en la Tabla 13. Luego, al entrenar y evaluar en el conjunto de test para un modelo SVM con distintos kernels se obtuvo que el de mejor rendimiento fue SVM RBF con Precision 0.90, Recall 0.90, F1-score 0.90 y Accuracy 0.90 (Tabla 14).

Para SVM RBF se obtuvo que hay pocos FP y FN en su matriz de confusión (Tabla 15), en particular tiene menos que LDA. Asimismo, al ver las métricas específicas de este modelo (Tabla 16) se observa que tuvo un muy buen rendimiento, con F1-Score igual al de Regresión Logística inicial (Tabla 5).

SVM clasifica al separar las clases maximizando el margen entre ellas, es decir, no es un modelo probabilístico ya que no modela ni $p(x|y)$ ni $p(y|x)$. Por tanto, las técnicas que se utilizan para abordar los SVC desde un punto probabilístico son

- Platt Scaling (SVC(probability=True)): Ajusta una función sigmoide sobre las distancias al hiperplano obtenidas por *decision function*.
 - Se entrena una regresión logística secundaria sobre los scores del SVM mediante una validación cruzada interna, permitiendo usar los métodos `predict_proba()` y `predict_log_proba()` del modelo SVM.

- CalibratedClassifierCV: Utiliza sigmoid o isotonic para calibrar probabilidades.
 - Método general para calibrar probabilidades en cualquier clasificador, no solo SVM.
 - Usar sigmoid es equivalente a Platt Scaling, mientras que isotonic regression calibra de forma más flexible ante conjuntos grandes.
 - Realiza una validación cruzada externa para evitar sobreajuste durante la calibración.

En cuanto a las limitaciones tenemos que las "probabilidades" resultantes son calibradas y no una verosimilitud derivada de un modelo generativo, es decir, no se pueden usar directamente para AIC/BIC.

Además, el proceso de calibración es costoso computacionalmente, ya que implica un proceso adicional de validación cruzada sobre el conjunto de entrenamiento.

Finalmente, podría suceder que una muestra sea clasificada como positiva pese a que se obtenga $\text{predict_proba} < 0.5$, o viceversa, mostrando inconsis.

Dentro de las ventajas, esta que se puede interpretar la salida del SVM como una probabilidad, permitiendo comparar modelos probabilísticos y no probabilísticos bajo un nuevo marco común de evaluación probabilística. Esto también es útil si la decisión también requiere basarse en un umbral o análisis de riesgo probabilístico.

Información referenciada de (1) y (2).

Parte (g)

A partir de la Tabla 17 podemos ver los resultados obtenidos para todos los modelos.

Al comparar LDA con los de Regresión Logística (M1, M2, M3), destacando que a diferencia de tablas anteriores se tiene F1-Score y no F1-Score Mean, podemos ver el orden creciente de esta métrica por modelo fue M2 (0.875) < M3 (0.904) < LDA (0.905) < M1 (0.913), con el mismo orden para Accuracy y Recall, mientras que para precisión fue de M2 (0.858) < LDA (0.880) < M3 (0.887) < M1 (0.896). Cabe destacar que para CV F1 el orden varía, siendo M2 (0.856) < M1 (0.858) < LDA (0.867) < M3 (0.879).

En cuanto a AIC y BIC, podemos ver que LDA fue solo mejor que M2, indicando que no se ajusto tan bien a los datos como otros modelos de RL (M1, M3). Mientras que de acuerdo a BIC, LDA obtuvo el puntaje más alto, indicando que es el más complejo (619), y por tanto se preferirían los modelos de Regresión Lineal (589, 583 y 564).

El modelo a seleccionar sería M3 (Regresión Logística) ya que tiene la mayor CV F1 (0.879 ± 0.024) indicando mejor generalización promedio y baja varianza entre los folds. Asimismo, M3 también tiene AIC y BIC más bajos que M1

y LDA, lo que indica que consigue buen ajuste con menos parámetros ($d = 11$ vs 16 en M1).

En cuanto a los supuestos principales de LDA las features (condicionadas a cada clase) siguen una distribución normal multivariante. Asimismo, las clases comparten la misma matriz de covarianza (cumple homocedasticidad).

En el dataset trabajado si bien algunas variables tiene una distribución similar a la normal (Age, RestingBP, Cholesterol, MaxHR, etc), el supuesto no se cumpliría ya que también existen muchas binarias a las cuales se añaden las que se transformaron en dummies. Debido a la presencia de las variables categoricas tambien sucederá que las covarianzas entre clases difieran, lo que contradeciría o al menos pondría en duda el segundo supuesto para la homocedasticidad. En términos de comparación con la Regresión Logística LDA rindió casi igual a M3 pero no mejor, y esto se debe a que sus supuestos no están perfectamente cumplidos, en caso de que si lo hicieran, se esperaría que LDA domine.

En cuanto a las limitaciones de LDA y Regresión Logística esta que ambos modelos generan fronteras de decisión lineales en el espacio de las features, impidiendo capturar las interacciones o relaciones no lineales entre variables. Además, dado que se trata de datos médicos, esto podría ser especialmente cierto.

Para investigar formalmente la presencia de relaciones no lineales el primer paso seria un análisis exploratorio entre variables junto a scatter plots o clusters que entreguen patrones adicionales al EDA simple realizado en la parte 'a' que se centró en ver las distribuciones de valores.

Posteriormente, se pueden probar modelos no lineales (Random Forest/ Gradient Boost) o Redes Neuronales y comprobar si CV F1 o AUC mejoran en comparación de la Regresión Logística.

En cuanto a reglas generales (heurísticas) para comparar modelos mediante los valores de AIC y BIC tenemos que:

$$\Delta AIC = AIC_i - AIC_{min}$$

- 0–2: modelos equivalentes (evidencia sustancial a favor del modelo i).
- 4–7: menos apoyo para el modelo i .
- 8–10: prácticamente sin apoyo para el modelo i .

$$\Delta BIC = BIC_i - BIC_{min}$$

- 0–2: Ambos son modelos comparables.
- 2–6: Moderada preferencia por el modelo con menor BIC.

- 7-10: Clara preferencia por el modelo con menor BIC
- > 10 : Se puede descartar el modelo con mayor BIC.

El AIC_{min} obtenido fue 513.583 para M3. Esto significa que se obtiene:

- $\Delta AIC(M1) \approx 25.17$: Muy fuerte evidencia a favor de M3.
- $\Delta AIC(M2) \approx 19.07$: Muy fuerte evidencia a favor de M3
- $\Delta AIC(LDA) \approx 55.08$: Extremadamente fuerte evidencia a favor de M3

El BIC_{min} obtenido fue de 564.16 para M3. Esto significa que se obtiene:

- $\Delta BIC(M1) \approx 2.18$: M1 y M3 son equivalentes.
- $\Delta BIC(M2) \approx 37.47$: M2 es muy inferior a M3.
- $\Delta BIC(LDA) \approx 32.09$: LDA es muy inferior a M3.

En base a estas reglas podemos decir que se confirma que el modelo seleccionado es el mejor mediante los criterios AIC y BIC puesto que en AIC solo M1 fue equivalente, mientras que en BIC ninguno fue tan bueno.

Esta regla de diferencias se basa en los Akaike Weights (3) los cuales son una medida de cuánta probabilidad tiene cada modelo de ser el mejor según AIC o BIC, permitiendo así elegir el mejor de acuerdo a cada criterio.

Finalmente, al incorporar SVM RBF en las comparaciones mediante F1-Score, a partir de la Tabla 17 podemos ver que tiene un desempeño muy similar a LDA y M3, con una diferencia de 0.004 y 0.005 respectivamente. En cuanto a M1 (0.913), SVM RBF (0.90) es ligeramente peor. Sin embargo, al guiarse por CV F1 tenemos que SVM solo es peor que el mejor modelo de RL M3.

Respecto a las situaciones en las que la falta de un marco de verosimilitud, esta puede ser una desventaja cuando se quiere cuantificar el nivel de confianza que tuvo la predicción. Por ejemplo, para diagnosticar que se predijo que el paciente tiene la enfermedad al corazón, también es importante indicar el nivel de confianza ya que podría cambiar decisiones médicas (tratamientos, exámenes o priorización de pacientes).

Por otro lado, las situaciones en las que el enfoque de maximización del margen vía SVM resulta superior son aquellas en donde se quiere tener una buena generalización por sobre la inferencia estadística. SVM resulta más robusto en presencia de ruido (resistencia a outliers), al mismo tiempo

que este enfoque puede resultar muy útil si la frontera es no lineal, y en donde combinado con cierto kernel, resulte mejor a otros modelos (por ejemplo LDA si no se cumplen los supuestos).

References

- [1] Scikit-learn Documentation, *Support Vector Machines — scikit-learn*, <https://scikit-learn.org/stable/modules/svm.html#scores-probabilities>,
- [2] Sklearn, *SVC Probability Parameter in scikit-learn*, <https://sklearn.com/sklearn-svc-probability-parameter/>,
- [3] Wagenmakers, E.-J., & Farrell, S. (2004). *AIC model selection using Akaike weights*. *Psychonomic Bulletin & Review*, 11(1), 192–196. Springer. Disponible en: <https://link.springer.com/article/10.3758/BF03206482>

A. Anexo

A.1. Pregunta 1

A.1.1. PARTE A

Table 1. Cantidad de valores nulos por columna en el conjunto de datos.

Columna	Valores nulos
Age	0
Sex	0
ChestPainType	0
RestingBP	0
Cholesterol	0
FastingBS	0
RestingECG	0
MaxHR	0
ExerciseAngina	0
Oldpeak	0
ST_Slope	0
HeartDisease	0

Table 2. Resumen estadístico de las variables del conjunto de datos.

Medida	Age	Sex	ChestPainType	RestingBP	Cholesterol	FastingBS	RestingECG	MaxHR	ExerciseAngina	Oldpeak	ST_Slope	HeartDisease
count	918.000	918	918	918.000	918.000	918.000	918	918.000	918	918.000	918	918.000
unique	NaN	2	4	NaN	NaN	NaN	3	NaN	2	NaN	3	NaN
top	NaN	M	ASY	NaN	NaN	NaN	Normal	NaN	N	NaN	Flat	NaN
freq	NaN	725	496	NaN	NaN	NaN	552	NaN	547	NaN	460	NaN
mean	53.511	NaN	NaN	132.397	198.800	0.233	NaN	136.809	NaN	0.887	NaN	0.553
std	9.433	NaN	NaN	18.514	109.384	0.423	NaN	25.460	NaN	1.067	NaN	0.497
min	28.000	NaN	NaN	0.000	0.000	0.000	NaN	60.000	NaN	-2.600	NaN	0.000
25%	47.000	NaN	NaN	120.000	173.250	0.000	NaN	120.000	NaN	0.000	NaN	0.000
50%	54.000	NaN	NaN	130.000	223.000	0.000	NaN	138.000	NaN	0.600	NaN	1.000
75%	60.000	NaN	NaN	140.000	267.000	0.000	NaN	156.000	NaN	1.500	NaN	1.000
max	77.000	NaN	NaN	200.000	603.000	1.000	NaN	202.000	NaN	6.200	NaN	1.000

A.1.2. PARTE B

Table 3. Matrices de confusión con indicadores para los conjuntos de entrenamiento y prueba

Train			Test		
	Pred: 0	Pred: 1		Pred: 0	Pred: 1
Real: 0	TN = 276	FP = 52	Real: 0	TN = 71	FP = 11
Real: 1	FN = 54	TP = 352	Real: 1	FN = 7	TP = 95

Table 4. Métricas de clasificación para el conjunto de entrenamiento

Clase / Métrica	Precision	Recall	F1-score	Support
0	0.84	0.84	0.84	328
1	0.87	0.87	0.87	406
Accuracy			0.86	734
Macro avg	0.85	0.85	0.85	734
Weighted avg	0.86	0.86	0.86	734




Figure 1. Distribución de la variable objetivo en todo el dataset.

Table 5. Métricas de clasificación para el conjunto de testeo

Clase / Métrica	Precision	Recall	F1-score	Support
0	0.91	0.87	0.89	82
1	0.90	0.93	0.91	102
Accuracy			0.90	184
Macro avg	0.90	0.90	0.90	184
Weighted avg	0.90	0.90	0.90	184

Table 6. Variables utilizadas por cada modelo

Modelo	Variables utilizadas
M1	Todas las variables disponibles.
M2	FastingBS, ChestPainType_ATA, ChestPainType_NAP, ExerciseAngina_Y, ST_Slope_Flat, ST_Slope_Up.
M3	Cholesterol, FastingBS, MaxHR, Oldpeak, Sex_M, ChestPainType_ATA, ChestPainType_NAP, ExerciseAngina_Y, ST_Slope_Flat, ST_Slope_Up.




Figure 2. Distribución de las variables numéricas.

A.1.3. PARTE D

Table 7. Hiperparámetros de los modelos M1, M2 y M3

Hiperparámetro	M1	M2	M3
penalty	'l1'	'l2'	None
dual	False	False	False
tol	0.0001	0.0001	0.0001
C	1.0	1.0	1.0
fit_intercept	True	True	True
intercept_scaling	1	1	1
class_weight	'balanced'	None	None
random_state	42	42	42
solver	'saga'	'lbfgs'	'lbfgs'
max_iter	5000	5000	5000
multi_class	'deprecated'	'deprecated'	'deprecated'
verbose	0	0	0
warm_start	False	False	False
n_jobs	None	None	None
l1_ratio	None	None	None

Table 8. Comparación de modelos: log-verosimilitud, AIC, BIC y F1 CV

Modelo	loglik	d	AIC	BIC	CV F1 (mean)	CV F1 (std)
M1	-241.88	16	515.76	589.34	0.858	0.028
M2	-268.52	7	551.05	583.24	0.856	0.026
M3	-245.79	11	513.58	564.17	0.879	0.024




Figure 3. Distribución de las variables categóricas.

A.1.4. PARTE E

Table 9. Variables utilizadas para el entrenamiento del modelo LDA

N°	Variable
1	Age
2	RestingBP
3	Cholesterol
4	FastingBS
5	MaxHR
6	Oldpeak
7	Sex_M
8	ChestPainType_ATA
9	ChestPainType_NAP
10	ChestPainType_TA
11	RestingECG_Normal
12	RestingECG_ST
13	ExerciseAngina_Y
14	ST_Slope_Flat
15	ST_Slope_Up

Table 10. Matriz de confusión del modelo LDA en el conjunto de test

		Predicha	
		0	1
Real	0	69 (TN)	13 (FP)
	1	7 (FN)	95 (TP)

Table 11. Métricas del modelo LDA en el conjunto de test

Clase	Precision	Recall	F1-Score	Support
0	0.91	0.84	0.87	82
1	0.88	0.93	0.90	102
Accuracy			0.89	184
Macro Avg	0.89	0.89	0.89	184
Weighted Avg	0.89	0.89	0.89	184

Table 12. Resumen de criterios de información del modelo LDA ($K = 2$, $M = 15$)

Modelo	loglik	d	AIC	BIC
LDA (densidad gaussiana)	-7783.88	151	15869.76	16564.13
LDA (condicional)	-256.84	16	545.67	619.25

A.1.5. PARTE F

Table 13. Variables utilizadas en el modelo SVM

Nº	Variable
1	Age
2	RestingBP
3	Cholesterol
4	FastingBS
5	MaxHR
6	Oldpeak
7	Sex_M
8	ChestPainType_ATA
9	ChestPainType_NAP
10	ChestPainType_TA
11	RestingECG_Normal
12	RestingECG_ST
13	ExerciseAngina_Y
14	ST_Slope_Flat
15	ST_Slope_Up

Table 14. Resumen de métricas macro en el conjunto de test para variantes de SVM

Modelo SVM	Precision (macro avg)	Recall (macro avg)	F1-score (macro avg)	Accuracy
SVM Linear	0.88	0.87	0.88	0.88
SVM RBF	0.90	0.90	0.90	0.90
SVM Poly	0.89	0.88	0.88	0.89
SVM Sigmoid	0.80	0.79	0.79	0.80

Table 15. Matriz de confusión del modelo SVM RBF en el conjunto de test

		Predicha	
		0	1
Real	0	70 (TN)	12 (FP)
	1	6 (FN)	96 (TP)

Table 16. Métricas del modelo SVM RBF en el conjunto de test

Clase	Precision	Recall	F1-Score	Support
0	0.92	0.85	0.89	82
1	0.89	0.94	0.91	102
Accuracy			0.90	184
Macro Avg	0.90	0.90	0.90	184
Weighted Avg	0.90	0.90	0.90	184

A.1.6. PARTE G

Table 17. Resumen de métricas, criterios de información y CV F1 para todos los modelos

Modelo	Accuracy	Precision	Recall	F1	LogLik	d	AIC	BIC	CV F1 (mean)	CV F1 (std)
Logistic_M1	0.902	0.896	0.931	0.913	-241.881	16	515.761	589.337	0.858	0.028
Logistic_M2	0.859	0.858	0.892	0.875	-268.524	7	551.047	583.237	0.856	0.026
Logistic_M3	0.891	0.887	0.922	0.904	-245.791	11	513.583	564.166	0.879	0.024
LDA	0.891	0.880	0.931	0.905	-256.838	16	545.675	619.251	0.867	0.028
SVM_linear	0.880	0.880	0.870	0.880	-243.987	16	—	—	0.869	0.031
SVM_rbf	0.900	0.900	0.900	0.900	-200.451	16	—	—	0.881	0.024