
Reducción de dimensionalidad y SVC

Aprendizaje de Máquinas, MDS (Primavera 2025)

Patricio Espinoza A.^{*1} Francisco Vásquez L.^{*1,2} Álvaro Márquez² Víctor Hernández M.³

Abstract

Este documento contiene la resolución de los problemas de la Tarea 5 del ramo Aprendizaje de Máquinas del Máster en Ciencia de Datos de la Universidad de Chile.

1. Pregunta 1

Parte (a)

El conjunto de datos consiste en características de las células presentes en imágenes que permiten detectar el cáncer de mama.

La variable objetivo es 'diagnosis', que indica si el tumor es Maligno o Benigno.

A partir de las imágenes, se calcularon diez características principales para cada núcleo celular:

1. **radius:** media de las distancias desde el centro del núcleo hasta los puntos de su perímetro.
2. **texture:** desviación estándar de los valores de escala de grises (variabilidad de la textura).
3. **perimeter:** longitud del perímetro del núcleo celular.
4. **area:** área del núcleo celular.
5. **smoothness:** variación local en la longitud del radio (grado de suavidad de los bordes).
6. **compactness:** relación entre el perímetro y el área ($\text{perímetro}^2 / \text{área} - 1.0$).
7. **concavity:** grado de concavidad de las partes hundidas del contorno.
8. **concave points:** número de puntos o segmentos cóncavos del contorno.
9. **symmetry:** simetría del núcleo celular.
10. **fractal dimension:** medida de la complejidad del contorno ("aproximación de línea costera" - 1).

Para cada una de estas diez características se calcularon tres tipos de valores:

- **_mean:** valor promedio de la característica.
- **_se:** error estándar del valor medio (variabilidad interna en las mediciones).
- **_worst:** promedio de los tres valores más altos registrados para esa característica.

Resultando en las variables presentes en la Tabla 1, donde podemos ver que se descomponen en el promedio, desviación estándar y 'worst' o 'largest' que significa el promedio de los 3 valores más grandes para dicha característica. Además podemos ver que no hay nulos, y que la mayoría de datos son 'float64'.

En cuanto a la distribución de la variable objetivo 'diagnosis', a partir de la Tabla 2 se aprecia que predomina la Clase Benigna (357 casos o 62.75%) por sobre la Maligna (212 casos o 37.25%).

De la Figura 1 podemos ver que para varias características, como por ejemplo las distribuciones de radius_mean, concavity_mean, , texture_worst, perimeter_worst y concave_points_worst entre otras más, difieren claramente dependiendo de si se trata de un tumor Benigno o Maligno, lo que a priori nos permite identificar variables del dataset que deberían ser las más influyentes.

Al complementar esta observación con las estadísticas descriptivas, podemos ver que para aquellas variables 'mean' (Tablas 3 y 4) cuando es Maligno el promedio de valores de perimeter_mean y area_mean son mucho mayores a cuando es Benigno.

De igual forma, para aquellas 'se' (Tablas 5 y 6) se observa que el promedio y desviación estándar de perimeter_se y area_se es mucho mayor cuando el diagnóstico es Maligno que cuando es Benigno.

Finalmente, para las variables 'worst' (Tablas 7 y 8) destacan nuevamente perimet y area. En este caso también es mucho más claro que influye también concavity y concave, la cual también tuvo mayores valores en tablas anteriores para el caso Maligno.

Parte (b)

De la Figura 2 se pueden observar las proyecciones en dos dimensiones obtenidas mediante los métodos de reducción de dimensionalidad PCA, t-SNE, UMAP e Isomap, aplicados tanto sobre el conjunto original de datos como sobre una versión estandarizada de los mismos.

En general, se aprecia que la estandarización tiene un impacto significativo en la calidad de las proyecciones. Al escalar las variables, se evita que aquellas con mayor varianza (por ejemplo, radius_mean o area_mean) dominen el proceso de reducción, lo que permite una distribución más homogénea de los puntos en el espacio reducido. Esto genera una mayor dispersión y mejor separación entre las clases, haciendo más evidente la frontera entre tumores benignos y malignos.

Sin escalar los datos, las proyecciones tienden a mostrar grupos más compactos y solapados, ya que las magnitudes originales de las variables afectan directamente la distancia euclidiana empleada por los métodos de reducción.

Al escalar los datos, se observa una separación clara entre clases, aunque en tSNE y UMAP se pueden ver pequeños grupos de datos solapados en la frontera (o en tSNE al otro extremo del cluster azul).

Respecto a la proyección de nuevos datos, PCA e Isomap permiten transformar nuevas observaciones ya que ambos aprenden una transformación explícita basada en el entrenamiento. En cambio, t-SNE y UMAP no están diseñados para proyectar nuevos datos, porque no aprenden una función de mapeo fija entre el espacio original y el espacio reducido. Estos métodos optimizan las posiciones de todos los puntos de forma conjunta, de manera que incorporar un nuevo punto implicaría recalcular toda la proyección desde cero.

Esto implica que t-SNE y UMAP son principalmente herramientas exploratorias de visualización, mientras que PCA e Isomap pueden emplearse también como parte del procesamiento.

Parte (c)

De la Figura 3 se puede observar la matriz de correlación para las variables del dataset. Muchas variables que representan una misma característica (por ejemplo radius) pero que varían en si se enfocan en mean, se o worst tienen alta correlación entre si. Por ejemplo radius_mean y radius_worst.

Separando por 'mean', 'se' y 'worst' podemos ver a través de las Tablas 9, 10 y 11 que el Top 5 de características con mayor correlaciones entre ellas son distinguiendo por categoría son:

- radius y perimeter (mean, se y worst)
- radius y area (mean, se y worst)
- perimeter y area (mean, se y worst)
- concavity y concave points (mean, se y worst)
- compactness y concavity (mean, se y worst)
- compactness y fractal dimension (sólo se)

El hecho de que estas relaciones sean consistentes en las tres categorías (mean, se y worst) indica una fuerte redundancia de información que puede afectar a SVM. En particular, como SVM se basa en calculo de distancias, el que hayan dimensiones similares y con información muy similar provocará que ciertas direcciones del espacio tengan un peso excesivo, lo que a su vez puede implicar que el modelo ajuste los márgenes en estas dimensiones, capturando ruido y aumentando el riesgo de sobreajuste. Esta pérdida de ajuste representaría una baja en el criterio AIC, mientras que en términos de BIC tener múltiples dimensiones casi idénticas añade complejidad extra, y por tanto teniendo un bajo performance bajo este criterio.

Para agrupar las características se puede utilizar Análisis de Componentes Principales (PCA) ya que identifica aquellas que explican la mayor varianza de los datos, generando nuevas características ortogonales (no correlacionadas entre sí), reduciendo la dimensionalidad y eliminando la multicolinealidad.

Parte (d)

Mediante un split estratificado con proporción 80/20 se obtuvieron los conjuntos de entrenamiento y prueba de la Tabla 12, donde podemos ver un desbalance de clases, siendo la mayoritaria el diagnostico de tumor Benigno.

Parte (e)

Para SVC se tiene que:

- El Kernel es la función de transformación que proyecta los datos originales a un espacio de mayor dimensión, donde puedan ser separados más fácilmente. Los tipos más comunes son linear, poly, rbf y sigmoid.
- El hiperparámetro C controla el equilibrio entre maximizar el margen y minimizar los errores de clasificación. Un valor grande de C penaliza fuertemente los errores, lo que lleva a un margen más estrecho y un posible sobreajuste; en cambio, un valor pequeño permite un margen más amplio y puede mejorar la generalización del modelo.
- class_weight permite asignar un peso distinto a cada clase, aumentando la penalización por clasificar incorrectamente las clases minoritarias. Es especialmente

útil cuando el conjunto de datos está desbalanceado, ya que evita que el modelo favorezca excesivamente a la clase mayoritaria.

De las Tablas 13 y 14 se observa que el modelo SVC con escalado y sin reducción de dimensionalidad obtuvo resultados sólidos en ambas particiones. Las métricas de Precisión, Recall y F1-score superan el 0.95 tanto en entrenamiento como en prueba, lo que indica un buen equilibrio entre la capacidad de detectar casos positivos (tumores malignos) y la precisión al clasificarlos correctamente.

Las tasas de error también son bajas: la Tasa de Falsos Positivos (FPR) fue de 0 en entrenamiento y 0.013 en prueba, mientras que la Tasa de Falsos Negativos (FNR) fue de 0.035 y 0.071, respectivamente. Esto se traduce en una Specificity elevada (1.0 en entrenamiento y 0.98 en prueba), lo que sugiere que el modelo distingue correctamente la mayoría de los tumores benignos y solo comete unos pocos errores al clasificar los malignos.

Al comparar las métricas entre ambos conjuntos, se aprecia una ligera disminución en el rendimiento sobre el conjunto de prueba, lo cual es esperable y refleja un modelo que generaliza bien sin evidentes signos de sobreajuste (overfitting). Si el modelo estuviera sobreajustado, esperaríamos ver un desempeño casi perfecto en entrenamiento (por ejemplo, F1=1.0) y una caída abrupta en las métricas de prueba, lo que no ocurre en este caso.

De estos resultados se puede observar que SVM con escalado tuvo buenas métricas en ambos conjuntos, con una buena capacidad de generalización y sin indicios de sobreajuste.

Parte (f)

Dado que SVC se basa en distancias al hiperplano de decisión, este no tiene una probabilidad asociada. Para calcular su probabilidad se utiliza Platt Scaling, el cuál permite aplicar una regresión logística sobre los valores de decisión obtenidos por SVC.

De esta manera, las distancias al hiperplano se transforman en valores entre 0 y 1 que pueden interpretarse como probabilidades estimadas de pertenencia a cada clase. Estas probabilidades se calculan de forma posterior al entrenamiento principal y permiten utilizar métricas basadas en umbrales continuos, como el área AUC y la curva ROC que relaciona la Tasa de Verdaderos Positivos (TPR) con la Tasa de Falsos Positivos (FPR).

En particular, tenemos que AUC mide la capacidad de discriminación (1.0 = perfecto, 0.5 = azar), y en el caso de nuestro modelo SVC con escalado y sin uso de PCA, podemos ver de la Figura 4 que se obtuvo un $AUC = 0.995$ el cuál indica una gran capacidad discriminativa. Además, a partir de la curva ROC podemos ver como esta crece rápidamente

al inicio, apuntando hacia el cuadrante izquierdo superior (Alto TPR y bajo FPR), lo que indica que por ambos criterios el modelo tiene buen rendimiento.

Parte (g)

Se busco mejorar el rendimiento del modelo SVC (con escalado y sin PCA) mediante una búsqueda de hiperparámetros mediante GridSearch con validación cruzada ($K = 5$) y métrica objetivo F1. Para ello se usaron las combinaciones presentes en la Tabla 16. A partir de esto se obtuvo que los mejores hiperparámetros son:

$C : 10$, $class_weight : \text{None}$, $kernel : \text{rbf}$.

Los resultados para el conjunto de entrenamiento y prueba permiten, presentes en la Tabla 17 muestran que para ambos conjuntos se obtuvo una Accuracy alta (0.98 Entrenamiento, 0.97 Prueba), un F1-score alto (0.98 Entrenamiento, 0.96 Prueba) y un AUC alto también (1.0 Entrenamiento y 0.99 Prueba).

Respecto a las métricas anteriores obtenidas (Tabla 15) podemos observar que en entrenamiento la Accuracy sube ligeramente ($0.9868 \rightarrow 0.9890$) al igual que F1-score ($0.9820 \rightarrow 0.9851$), y también para AUC ($0.9824 \rightarrow 1.0$). Esto se repite para el conjunto de prueba, donde Accuracy pasa de 0.9649 a 0.9737, F1 de 0.9512 a 0.9630 y AUC de 0.9573 a 0.9931.

Estas diferencias en los resultados se explican por la optimización de parámetros del modelo SVC, los cuales generan un mejor ajuste del modelo a los datos. De haberse obtenido resultados más bajos, implicaría que los hiperparámetros por defecto del SVC implementado eran los que mejor se ajustaban.

Parte (h)

Respecto a los hiperparámetros obtenidos mediante GridSearch y los problemas o aspectos del modelo que abordan tenemos que:

C regula el margen de decisión. Un valor bajo implica una mayor regularización, permitiendo un margen más ancho y tolerando errores de clasificación para mejorar la capacidad de generalización. Por otra parte, un valor alto como el obtenido mediante GridSearch ($C = 10$) reduce la regularización y penaliza fuertemente los errores, obteniendo márgenes más ajustados a los datos de entrenamiento, lo que puede mejorar la precisión pero aumentar el riesgo de sobreajuste.

El kernel define la transformación del espacio de características en el cual el SVM buscará el hiperplano separador. Un kernel lineal asume que los datos son separables en su espacio original, mientras que un kernel RBF (Radial Basis Function), como el obtenido mediante GridSearch, permite capturar relaciones no lineales, proyectando los datos a un

espacio de mayor dimensión donde las clases pueden separarse con mayor facilidad.

Por último, `class_weight` maneja la ponderación de las clases durante el entrenamiento, ajustando la penalización por errores en clases minoritarias.

En particular, el valor alto de C que no presento sobre ajuste entre ambos conjuntos permite interpretar que los datos son lo suficientemente representativos como para preferir un margen más ajustado sin caer en sobreajuste. Por otra parte, el kernel nos indica que las relaciones entre variables son no lineales, mientras que `class_weight` indica que el desbalance entre clases no es grave y el modelo no requiere penalizar los errores de la clase minoritaria para obtener un buen desempeño.

Parte (i)

A partir de la Tabla 18 podemos ver que la mejor combinación de parámetros para AUC dio 0.9964, así como también fue la de F1-score con 0.9250 y se obtuvo para el conjunto de prueba escalado con PCA, con $C = 1$, `class_weight = None` y `kernel = linear`.

La mejor combinación de parámetros para Accuracy dio 0.9561 y se obtuvo para el conjunto escalado con UMAP, con $C = 1$, `class_weight = balanced` y `kernel = rbf`. En segundo lugar para F1 estuvo la combinación que obtuvo el mejor AUC y F1, con Accuracy = 0.9474.

Respecto a los datos escalados podemos decir que PCA_std (Ver Tabla 18) es el mejor modelo con $d = 2$ ($AUC=0.9964$, Accuracy=0.9474, F1=0.9250), mientras que al usar los datos originales el mejor modelo es PCA_original ($AUC=0.9825$, Accuracy=0.9123, F1=0.8684). Por otra parte, anteriormente (Tabla 15) habíamos obtenido que SVC con escalado y sin métodos de reducción de la dimensionalidad resultó en $AUC=0.9573$, Accuracy = 0.9649 y F1 = 0.9512.

A partir de estos resultados podemos ver claramente entre ambos tipos de datos (original y escalado) que el mejor método de reducción de dimensionalidad fue PCA, lo cuál se debe a que este busca las direcciones de mayor varianza en los datos y genera componentes ortogonales (no correlacionadas), lo cual reduce el ruido y la redundancia entre las variables.

Asimismo, observamos que el escalamiento resultó beneficioso para SVC, ya que la estandarización de las variables evita que aquellas con magnitudes mayores dominen el cálculo de distancias del kernel, lo que a su vez permite que el modelo encuentre fronteras de decisión más estables y balanceadas.

Por otra parte, al incluir SVC con escalado y sin métodos de reducción de dimensionalidad en la comparación, podemos

ver que se obtiene un AUC menor, Accuracy mayor, y un F1 mayor. Resultados más claros en la Tabla 19.

Esta diferencia puede explicarse por la misma reducción de dimensionalidad aplicada mediante PCA, la cual implica una pérdida parcial de información, ya que aunque las proyecciones a dos componentes capturan la mayor varianza, esta no es el total del conjunto original. Esto a su vez significa que el modelo SVC entrenado sobre los datos proyectados con PCA dispone de menos información discriminativa, lo que puede afectar levemente las predicciones punto a punto, reduciendo así Accuracy y F1-score.

Por otra parte, AUC puede mejorar respecto al modelo con escalado pero sin PCA, ya que la reducción de dimensionalidad también elimina ruido y correlaciones redundantes, lo que produce una frontera de decisión más estable y una mejor separación en el espacio reducido. Por tanto, el modelo sin reducción de dimensionalidad logra clasificar correctamente más casos (mayor Accuracy y F1), pero el modelo con PCA discrimina mejor entre clases a lo largo de todos los umbrales posibles, lo que se refleja en un AUC más alto.

Parte (j)

De la Tabla 20 podemos observar los resultados de entrenar SVC con RobustScaler y StandardScaler, con Hiperparámetros C:10, kernel:rbf y `class_weight=None`.

Entre los dos tipos de escaladores podemos ver que, en AUC-entrenamiento StandardScaler fue mayor a RobustScaler (1.0 vs 0.99), mientras que en AUC-prueba fue al revés (0.9923 vs 0.9937). Por el lado de Accuracy, ambos tuvieron los mismos valores para entrenamiento y prueba, así como también para F1.

Al compararlo con los de la Parte (g) (solo conjunto de prueba) podemos observar que ambos escalados consiguen mejor AUC, Accuracy y F1 que los tres tipos de SVC mostrados en la Tabla 19.

Al usar nuevamente GridSearch con la grilla de hiperparámetros de la Tabla 16 con estos dos tipos de escalado se obtuvieron los resultados presentes en la Tabla 21.

Observando primero los hiperparámetros encontrados, tenemos que para RobustScaler fueron los mismos que para la parte (g) (C:10, Kernel:rbf y `class_weight=None`), mientras que para StandardScaler solo cambio C a 1. Esto indica que para dicho escalador el modelo obtuvo mejores resultados mediante una mayor regularización, lo que permite un margen de decisión más ancho y a la vez tolera más los errores de clasificación.

Respecto a las métricas podemos ver que ambas son muy cercanas, para F1 CV se obtuvo 0.96696 con StandardScaler mientras que con RobustScaler fue levemente menor (0.96123). En AUC-Prueba StandardScaler obtuvo 0.995,

mientras que RobustScaler 0.994, y tanto la Accuracy como F1 en Prueba de ambos conjuntos dieron iguales (0.974 y 0.963 respectivamente).

Estos hiperparámetros fueron mantuvieron los mismos resultados para RobustScaler, mientras que para StandardScaler AUC-Prueba subió, y tanto Accuracy como F1 en el conjunto de Prueba se mantuvieron.

Luego, al seleccionar PCA como método de reducción de dimensionalidad, y aplicar ambos escaladores al conjunto de datos se obtuvieron las proyecciones de las Figuras 5 y 6. Para StandardScaler se puede observar una mayor dispersión para ambas clases, mientras que con RobustScaler esta dispersión se ve reducida, particularmente para la Clase Maligna. Otra observación es que con StandardScaler los datos de ambas clases se solapan menos, haciendo la frontera de decisión más visible, mientras que para RobustScaler estos se solapan mucho más.

Al aplicar un modelo de SVC sobre las proyecciones obtenidas con PCA, es esperable que el rendimiento sea ligeramente inferior en métricas como Accuracy o F1-score respecto al observado sobre el conjunto de datos original, esto es debido a que el proceso de reducción a dos dimensiones descarta parte de la información contenida en las variables menos relevantes.

Por otra parte, es esperable que métricas como AUC mejoren, como se menciona en la parte (i), por la eliminación de colinealidad y ruido en las variables, generando una frontera de decisión más estable.

A. Anexo

A.1. Pregunta 1

A.1.1. PARTE A

Table 1. Resumen de variables del conjunto de datos

N°	Variable	Valores no nulos	Tipo de dato
0	id	569	int64
1	diagnosis	569	object
2	radius_mean	569	float64
3	texture_mean	569	float64
4	perimeter_mean	569	float64
5	area_mean	569	float64
6	smoothness_mean	569	float64
7	compactness_mean	569	float64
8	concavity_mean	569	float64
9	concave points_mean	569	float64
10	symmetry_mean	569	float64
11	fractal_dimension_mean	569	float64
12	radius_se	569	float64
13	texture_se	569	float64
14	perimeter_se	569	float64
15	area_se	569	float64
16	smoothness_se	569	float64
17	compactness_se	569	float64
18	concavity_se	569	float64
19	concave points_se	569	float64
20	symmetry_se	569	float64
21	fractal_dimension_se	569	float64
22	radius_worst	569	float64
23	texture_worst	569	float64
24	perimeter_worst	569	float64
25	area_worst	569	float64
26	smoothness_worst	569	float64
27	compactness_worst	569	float64
28	concavity_worst	569	float64
29	concave points_worst	569	float64
30	symmetry_worst	569	float64
31	fractal_dimension_worst	569	float64

Table 2. Distribución de la variable objetivo *diagnosis*

Clase	Frecuencia	Porcentaje (%)
B (Benigno)	357	62.75
M (Maligno)	212	37.25
Total	569	100.00

Tarea 5, Aprendizaje de Maquinas. MDS, Universidad de Chile




Figure 1. Distribución de las variables continuas de acuerdo al tipo de diagnóstico.

Table 3. Variables _mean — Clase **Benigna**

Variable	count	mean	std	min	25%	50%	75%	max
radius_mean	357	12.1	1.8	7.0	11.1	12.2	13.4	17.9
texture_mean	357	17.9	4.0	9.7	15.2	17.4	19.8	33.8
perimeter_mean	357	78.1	11.8	43.8	70.9	78.2	86.1	114.6
area_mean	357	462.8	134.3	143.5	378.2	458.4	551.1	992.1
smoothness_mean	357	0.09	0.01	0.05	0.08	0.09	0.10	0.16
compactness_mean	357	0.08	0.03	0.02	0.06	0.08	0.10	0.22
concavity_mean	357	0.05	0.04	0.00	0.02	0.04	0.06	0.41
concave points_mean	357	0.03	0.02	0.00	0.02	0.02	0.03	0.09
symmetry_mean	357	0.17	0.02	0.11	0.16	0.17	0.19	0.27
fractal dimension_mean	357	0.06	0.01	0.05	0.06	0.06	0.07	0.10

Table 4. Variables _mean — Clase **Maligna**

Variable	count	mean	std	min	25%	50%	75%	max
radius_mean	212	17.5	3.2	11.0	15.1	17.3	19.6	28.1
texture_mean	212	21.6	3.8	10.4	19.3	21.5	23.8	39.3
perimeter_mean	212	115.4	21.9	71.9	98.7	114.2	129.9	188.5
area_mean	212	978.4	367.9	361.6	705.3	932.0	1203.8	2501.0
smoothness_mean	212	0.10	0.01	0.07	0.09	0.10	0.11	0.14
compactness_mean	212	0.15	0.05	0.05	0.11	0.13	0.17	0.35
concavity_mean	212	0.16	0.08	0.02	0.11	0.15	0.20	0.43
concave points_mean	212	0.09	0.03	0.02	0.06	0.09	0.10	0.20
symmetry_mean	212	0.19	0.03	0.13	0.17	0.19	0.21	0.30
fractal dimension_mean	212	0.06	0.01	0.05	0.06	0.06	0.07	0.10

Table 5. Variables _se — Clase **Benigna**

Variable	count	mean	std	min	25%	50%	75%	max
radius_se	357	0.284	0.113	0.112	0.207	0.258	0.342	0.881
texture_se	357	1.220	0.589	0.360	0.796	1.108	1.492	4.885
perimeter_se	357	2.000	0.771	0.757	1.445	1.851	2.388	5.118
area_se	357	21.135	8.843	6.802	15.260	19.630	25.030	77.110
smoothness_se	357	0.007	0.003	0.002	0.005	0.007	0.009	0.022
compactness_se	357	0.021	0.016	0.002	0.011	0.016	0.026	0.106
concavity_se	357	0.026	0.033	0.000	0.011	0.018	0.031	0.396
concave points_se	357	0.010	0.006	0.000	0.006	0.009	0.012	0.053
symmetry_se	357	0.021	0.007	0.010	0.016	0.019	0.024	0.061
fractal dimension_se	357	0.004	0.003	0.001	0.002	0.003	0.004	0.030

Table 6. Variables `_se` — Clase **Maligna**

Variable	count	mean	std	min	25%	50%	75%	max
radius_se	212	0.609	0.345	0.194	0.390	0.547	0.757	2.873
texture_se	212	1.211	0.483	0.362	0.893	1.103	1.429	3.568
perimeter_se	212	4.324	2.569	1.334	2.716	3.680	5.206	21.980
area_se	212	72.672	61.355	13.990	35.763	58.455	94.000	542.200
smoothness_se	212	0.007	0.003	0.003	0.005	0.006	0.008	0.031
compactness_se	212	0.032	0.018	0.008	0.020	0.029	0.039	0.135
concavity_se	212	0.042	0.022	0.011	0.027	0.037	0.050	0.144
concave points_se	212	0.015	0.006	0.005	0.011	0.014	0.017	0.041
symmetry_se	212	0.020	0.010	0.008	0.015	0.018	0.022	0.079
fractal dimension_se	212	0.004	0.002	0.001	0.003	0.004	0.005	0.013

Table 7. Estadísticas descriptivas de las variables `_worst` para la clase Benigna (B)

Variable	count	mean	std	min	25%	50%	75%	max
radius_worst	357	13.38	1.98	7.93	12.08	13.35	14.80	19.82
texture_worst	357	23.52	5.49	12.02	19.58	22.82	26.51	41.78
perimeter_worst	357	87.01	13.53	50.41	78.27	86.92	96.59	127.10
area_worst	357	558.90	163.60	185.20	447.10	547.40	670.00	1210.00
smoothness_worst	357	0.1250	0.0200	0.0712	0.1104	0.1254	0.1376	0.2006
compactness_worst	357	0.1827	0.0922	0.0273	0.1120	0.1698	0.2302	0.5849
concavity_worst	357	0.1662	0.1404	0.0000	0.0771	0.1412	0.2216	1.2520
concave points_worst	357	0.0744	0.0358	0.0000	0.0510	0.0743	0.0975	0.1750
symmetry_worst	357	0.2702	0.0417	0.1566	0.2406	0.2687	0.2983	0.4228
fractal dimension_worst	357	0.0794	0.0138	0.0552	0.0701	0.0771	0.0854	0.1486

Table 8. Estadísticas descriptivas de las variables `_worst` para la clase Maligna (M)

Variable	count	mean	std	min	25%	50%	75%	max
radius_worst	212	21.13	4.28	12.84	17.73	20.59	23.81	36.04
texture_worst	212	29.32	5.43	16.67	25.78	28.95	32.69	49.54
perimeter_worst	212	141.37	29.46	85.10	119.33	138.00	159.80	251.20
area_worst	212	1422.29	597.97	508.10	970.30	1303.00	1712.75	4254.00
smoothness_worst	212	0.1448	0.0219	0.0882	0.1305	0.1435	0.1560	0.2226
compactness_worst	212	0.3748	0.1704	0.0513	0.2445	0.3564	0.4479	1.0580
concavity_worst	212	0.4506	0.1815	0.0240	0.3264	0.4049	0.5562	1.1700
concave points_worst	212	0.1822	0.0463	0.0290	0.1528	0.1820	0.2107	0.2910
symmetry_worst	212	0.3235	0.0747	0.1565	0.2765	0.3103	0.3592	0.6638
fractal dimension_worst	212	0.0915	0.0216	0.0550	0.0763	0.0876	0.1026	0.2075

A.1.2. PARTE B




Figure 2. Métodos de reducción de dimensionalidad con $d = 2$ para los datos originales y escalados. Maligno=1 y Benigno=0.

A.1.3. PARTE C




Figure 3. Matriz de correlación de las variables.

Table 9. Top correlaciones entre variables `_mean`

Variable 1	Variable 2	Correlación
radius_mean	perimeter_mean	0.997855
radius_mean	area_mean	0.987357
perimeter_mean	area_mean	0.986507
concavity_mean	concave points_mean	0.921391
compactness_mean	concavity_mean	0.883121

Table 10. Top correlaciones entre variables _se

Variable 1	Variable 2	Correlación
radius_se	perimeter_se	0.972794
radius_se	area_se	0.951830
perimeter_se	area_se	0.937655
compactness_se	fractal_dimension_se	0.803269
compactness_se	concavity_se	0.801268

Table 11. Top correlaciones entre variables _worst

Variable 1	Variable 2	Correlación
radius_worst	perimeter_worst	0.993708
radius_worst	area_worst	0.984015
perimeter_worst	area_worst	0.977578
compactness_worst	concavity_worst	0.892261
concavity_worst	concave points_worst	0.855434

A.1.4. PARTE D

Table 12. Tamaños y distribución de clases en los conjuntos de entrenamiento y prueba

Conjunto	Tamaño total	Clase 0 (Benigna)	Clase 1 (Maligna)
Entrenamiento	455	285	170
Prueba	114	72	42

A.1.5. PARTE E

Table 13. Métricas de rendimiento del modelo SVM en el conjunto de entrenamiento, con escalado y sin PCA

Clase	Precision	Recall	F1-score	Support
0	0.98	1.00	0.99	285
1	1.00	0.96	0.98	170
Accuracy			0.99	455
Macro avg	0.99	0.98	0.99	455
Weighted avg	0.99	0.99	0.99	455

Table 14. Métricas de rendimiento del modelo SVM en el conjunto de prueba, con escalado y sin PCA

Clase	Precision	Recall	F1-score	Support
0	0.96	0.99	0.97	72
1	0.97	0.93	0.95	42
Accuracy			0.96	114
Macro avg	0.97	0.96	0.96	114
Weighted avg	0.97	0.96	0.96	114

Table 15. Resultados globales del modelo SVM en entrenamiento y prueba

Métrica	Entrenamiento	Prueba
Accuracy	0.9868	0.9649
Precision	1.0000	0.9750
Recall (Sensibilidad)	0.9647	0.9286
Specificity	1.0000	0.9861
F1-score	0.9820	0.9512
FPR	0.0000	0.0139
FNR	0.0353	0.0714
TP	164.0	39.0
TN	285.0	71.0
FP	0.0	1.0
FN	6.0	3.0
AUC	0.9824	0.9573

A.1.6. PARTE F




Figure 4. Curva ROC y Área AUC del modelo SVC con escalado y sin PCA sobre el conjunto de prueba.

A.1.7. PARTE G

Table 16. Hiperparámetros utilizados en la búsqueda en malla (*GridSearchCV*) para el modelo SVC con escalado y sin PCA

Hiperparámetro	Valores evaluados
kernel	['linear', 'poly', 'rbf', 'sigmoid']
C	[0.1, 1, 10]
class.weight	['balanced', None, {0:1, 1:5}]

Table 17. Resultados del modelo SVC (con escalado, sin PCA)

Métrica	Entrenamiento	Prueba
Accuracy	0.9890	0.9737
F1-score	0.9851	0.9630
AUC	1.0000	0.9931

Hiperparámetros: C=10, kernel='rbf', class_weight=None.

A.1.8. PARTE I

Table 18. Comparación de métricas con métodos de reducción de dimensionalidad para SVC en Prueba

Proyección	Mejores Parámetros	AUC	Accuracy	F1-Score
PCA_std	{'C': 1, 'class_weight': None, 'kernel': 'linear'}	0.9964	0.9474	0.9250
UMAP_std	{'C': 1, 'class_weight': 'balanced', 'kernel': 'rbf'}	0.9927	0.9561	0.9380
Isomap_std	{'C': 10, 'class_weight': None, 'kernel': 'linear'}	0.9924	0.9298	0.8970
PCA_original	{'C': 1, 'class_weight': 'balanced', 'kernel': 'linear'}	0.9825	0.9123	0.8680
UMAP_original	{'C': 0.1, 'class_weight': None, 'kernel': 'rbf'}	0.9722	0.8860	0.8210
Isomap_original	{'C': 0.1, 'class_weight': None, 'kernel': 'linear'}	0.9673	0.8772	0.8100

Table 19. Comparación de desempeño del modelo SVC en conjunto de prueba al escalar y aplicar reducción de dimensionalidad

Versión del modelo	AUC	Accuracy	F1-Score
SVC con escalado (sin reducción)	0.9573	0.9649	0.9512
SVC con escalado + PCA	0.9964	0.9474	0.9250
SVC sin escalado + PCA	0.9825	0.9123	0.8684

A.1.9. PARTE J

Table 20. Resultados del modelo SVC con distintos métodos de escalado

Escalador	AUC_train	AUC_test	Acc_train	Acc_test	F1_train	F1_test
StandardScaler	1.000000	0.992725	0.989011	0.973684	0.985075	0.962963
RobustScaler	0.999959	0.993717	0.989011	0.973684	0.985075	0.962963

Hiperparámetros: {"C": 10, "kernel": "rbf", "class_weight": None}

Table 21. Resultados de GridSearchCV para el modelo SVC con distintos métodos de escalado

Escalador	Mejor F1 (CV)	AUC_test	Acc_test	F1_test
StandardScaler	0.96696	0.994709	0.973684	0.962963
RobustScaler	0.96193	0.993717	0.973684	0.962963

Mejores hiperparámetros encontrados:

StandardScaler: {"C": 1, "class_weight": None, "kernel": "rbf"}
RobustScaler: {"C": 10, "class_weight": None, "kernel": "rbf"}




Figure 5. Proyección mediante PCA a los datos escalados con StandardScaler.




Figure 6. Proyección mediante PCA a los datos escalados con RobustScaler.