
Naïve Bayes

Aprendizaje de Máquinas, MDS (Primavera 2025)

Patricio Espinoza A.^{*1} Francisco Vásquez L.^{*1,2} Álvaro Márquez² Víctor Hernández M.³

Abstract

Este documento contiene la resolución de los problemas de la Tarea 2 del ramo Aprendizaje de Máquinas del Mágister en Ciencia de Datos de la Universidad de Chile.

1. Pregunta 1

Dado un evento Z tal que una persona porta la infección. Y $\bar{Z}$ es no tener la infección. Tenemos los eventos donde el test puede dar positivo T^+ o negativo T^- , con tasas iguales y conocidas. Por otra parte, p es la probabilidad conocida de que el test sea correcto. Luego $P(Z)$ es la probabilidad a priori de estar infectado (prevalencia).

Parte (a)

La probabilidad de que el test salga positivo dado que la persona está infectada es $P(T^+|Z) = p$, mientras que su contraparte es $P(T^-|\bar{Z}) = p$.

A partir de esto obtenemos que $P(T^+|\bar{Z}) = 1 - p$ y $P(T^-|Z) = 1 - p$.

1. Por Ley de Probabilidades Totales:

$$P(T^+) = P(T^+|Z)P(Z) + P(T^+|\bar{Z})P(\bar{Z})$$
$$\Rightarrow P(T^+) = pP(Z) + (1-p)(1-P(Z))$$

2. Por Teorema de Bayes:

$$P(\bar{Z}|T^+) = \frac{P(T^+|\bar{Z})P(\bar{Z})}{P(T^+)}$$
$$\Rightarrow P(\bar{Z}|T^+) = \frac{(1-p)(1-P(Z))}{pP(Z) + (1-p)(1-P(Z))}$$

3. Número esperado de persoans no infectadas entre los diagnosticados positivamente:

$$\bar{N}_{FP} = N_+ \cdot P(\bar{Z}|T^+) = N_+ \cdot \frac{(1-p)(1-P(Z))}{pP(Z) + (1-p)(1-P(Z))}$$

Parte (b)

Con una exactitud del test $p = 0.95$, prevalencia $P(Z) = 1/10.000$ y para $N_+ = 10.000$. Se obtiene que:

$\Rightarrow \hat{N}_{FP} = 9.981$ es el número de personas estimado que no tienen la enfermedad dentro de las 10.000 que testearon positivo a Z .

Con $p = 0.5$ se obtiene que un estimado de $\hat{N}_{FP} = 9.999$ personas no tiene la enfermedad, es decir, casi ninguno.

A través de ambos casos se observa que aunque en un inicio la exactitud del test era alta, aún así la gran mayoría de personas seguramente no estaba infectada debido a la baja prevalencia con la que se trabaja. Esto se hizo aún más notorio cuando la exactitud del test bajo al 50%.

Dentro de los análisis a destacar esta que, frente a una enfermedad muy rara, con una prevalencia similar a la que se tiene en este caso, se requieren test con una gran sensibilidad para que realmente no predominen los falsos positivos.

Parte (c)

La diferencia entre el paradigma frecuentista y el bayesiano al interpretar las probabilidades radica en que el primero entiende la probabilidad como la frecuencia relativa objetiva de un evento al repetir un experimento muchas veces, mientras que el bayesiano la interpreta como un grado de creencia subjetivo que puede actualizarse al incorporar nueva evidencia mediante el teorema de Bayes.

En el caso del test de la enfermedad, un frecuentista diría que el test tiene una exactitud del 95% y que la prevalencia es de 1 en 10.000, considerando esos valores como parámetros fijos y que la incertidumbre proviene solo del muestreo. En cambio, un bayesiano pondría el foco en la hipótesis misma y cuestionaría "dado que una persona salió positiva, ¿cuál es la probabilidad de que realmente esté enferma?", actualizando la probabilidad a posteriori con la información observada

2. Pregunta 2

Se modela la cantidad de pasajeros (y) respecto al tiempo (x). Como: $y = f_\theta(x) + \eta$

Donde θ son los parámetros de la función f que se deben ajustar, y $\eta \sim N(0, \sigma_n^2)$ es ruido gaussiano.

Parte a

A partir de la Figura 1 se puede apreciar los conjuntos de entrenamiento y test con un número de pasajeros en incremento periódico por mes.

Parte b

En la Figura 2 se muestran los modelos polinomiales de grado 1, 2, 3, 4 y 5. Se observa que, en general, ninguno de ellos logra capturar adecuadamente la periodicidad de los datos. En particular, el modelo de grado 5 presenta una caída pronunciada después del mes 100.

Parte c

A partir de la Tabla 1 se puede observar como MSE, la cual penaliza más fuerte errores mayores, tiene un valor elevado, indicando una oscilación mayor del polinomio como ocurre en el grado 5.

MAE por otra parte permite comprender el error típico absoluto en el conjunto de datos, al igual que MSE, varía levemente entre los grados 1 a 4, pero se dispara para el grado 5.

Asimismo, R^2 permite medir la explicabilidad del modelo, a medida que se incrementa el grado, se observa una tendencia a que esta explicabilidad empeore, teniendo incluso valores negativos para los grados 3 y 5, indicando que dichos modelos son peores que predecir la media.

Finalmente MSLE penaliza los errores relativos en escala logarítmica, se observa que varía poco entre los grados, a excepción del grado 5 en donde al igual que para otras métricas su valor se dispara.

Los datos con los que se trabajan corresponde al conteo de pasajeros, de forma creciente y con oscilaciones. En particular MSLE sería la mejor métrica ya que permite penalizar errores relativos y es menos sensible a la escala en aumento de los pasajeros a lo largo de los meses, capturando mejor el impacto de subestimar valores grandes.

A partir de la figura 2, que muestra las curvas para los datos de entrenamiento, podemos comprender mejor el comportamiento de los resultados obtenidos en las métricas del conjunto de test. En particular, entre los grados 1 y 3 hay una tendencia lineal, en el grado 4 se nota un mejor ajuste al incrementar el grado, aunque por debajo de uno lineal. Sin embargo el grado 5 falla al intentar capturar la periodicidad, divergiendo completamente hacia abajo, coincidiendo con los altos valores para MSE, MAE, R^2 y MSLE de la Tabla 1. En base a esto, se puede observar que cuando x aumenta se espera que los los polinomios tiendan a divergir, por lo que no son buenos modelos para extrapolar ni capturar el patrón de los datos periódicos.

Parte d

Denotando al polinomio de la parte anterior como f_{pol} . Se modela la señal tal que $y = f_{pol} + \theta_1 \sin(\theta_2 x + \theta_3) e^{\theta_4 x} + \eta$ con $\eta \sim N(0, \sigma_n^2)$

A partir de los resultados obtenidos en la Tabla 2 se puede determinar que tanto MSE como MAE son relativamente altos (6626 y 76,6 respectivamente) y por tanto hay errores grandes. En promedio, el error absoluto es de ~ 73 pasajeros.

Por otra parte, el R^2 es negativo (-0,083), lo que significa que el modelo ajustado es peor que simplemente predecir el promedio de los datos de test. Finalmente, el MSLE también es bajo (0.0343), indicando que el modelo no se aleja demasiado de los valores reales.

En conclusión, el ajuste no es bueno, y el modelo falla al intentar capturar la tendencia periódica mediante la sinusoidal. Además, el ajuste es muy sensible al valor inicial de θ_4 , con el valor sugerido el optimizador encuentra un ajuste razonable. Sin embargo, con otros valores iniciales, la optimización puede caer en mínimos locales como se observa en la figura 3, resultando en métricas peores (MSE y MAE altos, R^2 negativo). Lo que nuevamente muestra que el problema no es lineal y recuerda la importancia de las condiciones iniciales para el modelo.

Parte e

Denotando como $f^{pol-sin}$ a la función f_θ encontrada en la parte anterior. Se agrega una nueva componente sinusoidal tal que:

$$y = f_\theta + \eta = f^{pol-sin} + \theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x} + \eta$$

Al utilizar un polinomio de grado 3, se obtuvieron los resultados de la Tabla 3. Podemos observar que MSE y MAE bajaron (6626 $\rightarrow$ 4194 MSE y 72,67 $\rightarrow$ 52,22 MAE), mientras que R^2 aumentó (-0,0830 $\rightarrow$ 0.3144) y MSLE bajó (0,0343 $\rightarrow$ 0,0184), indicando claras mejoras al integrar la sinusoidal.

Parte f

Respecto a los polinomios de grado 1 al 5, el mejor desempeño ocurrió con grados bajos (1 y 4), donde el R^2 es positivo (~ 0.18 para Grado 1). Con grado 5 el modelo colapsó, tanto MSE como MSLE se dispararon, y R^2 se volvió fuertemente negativo (-45,35), lo que evidencia un sobreajuste y mala capacidad de generalización. En resumen, los polinomios simples capturan una tendencia creciente, pero no la periodicidad.

Posteriormente se combinó un polinomio de grado 3 con una sinusoidal. Los parámetros estimados ($\theta_1, \dots, \theta_4$) de la Tabla 2 corresponden a la onda sinusoidal modulada exponencialmente. Sin embargo, los resultados fueron muy similares al polinomio puro (MSE ≈ 6627 , $R^2 \approx -0.08$), lo que muestra que una sola senoide no logra capturar la periodicidad compleja de los datos.

Al añadir una segunda senoide ($\theta_5, \dots, \theta_8$) el ajuste mejoró drásticamente: MSE bajó a 4194, MAE bajó a 52, R^2 subió a 0.31, y MSLE se redujo a 0.018. Este cambio indica que el modelo si empezó a capturar tanto la tendencia global creciente (vía polinomio) como la periodicidad (vía sinusoides).

De forma específica, el rol del polinomio es representar la tendencia de crecimiento en el número de pasajeros a lo largo del tiempo (meses). La primera senoide modulada introduce oscilaciones de baja frecuencia, aunque no fue suficiente por sí sola. Finalmente, la Segunda senoide modulada agrega otra frecuencia que captura mejor la estacionalidad real de los datos.

Esta construcción de múltiples componentes permitió que el modelo final tuviera el mejor ajuste en términos de predicción. Esto se confirma con las comparaciones de los resultados de las distintas predicciones, donde, a medida que se añadieron las componentes, tanto MSE, MAE como MSLE disminuyeron. Lo mismo se observa para la verosimilitud, la cual, al maximizarse para encontrar los parámetros θ_i , impactó directamente en la reducción de las métricas mencionadas.

Si bien es posible entrenar todo de una sola vez, este no sería el mejor camino debido a la complejidad del problema, este es no lineal y multimodal. Además, ajustar todos los parámetros simultáneamente aumentaría la dificultad de convergencia y la sensibilidad a los valores iniciales. Por tanto, la estrategia realizada por etapas (polinomio $\rightarrow$ polinomio+1 senoide $\rightarrow$ polinomio+2 sinusoides) permitió estabilizar el ajuste e interpretar mejor cada componente.

3. Pregunta 3

Parte a

Al implementar Naïve Bayes Classifier con conjuntos de entrenamiento y test en proporciones 80/20 respectivamente, se obtuvieron los resultados de la Tabla 4. En esta se puede observar que las probabilidades condicionales para Windy son todas superiores a 0,447, mientras que para Outlook varía mucho más, con un mínimo de 0,044 y un máximo de 0,551.

Además, en cuanto a los valores de μ y σ , tenemos que las medias tuvieron valores cercanos para las clases de cada variable. Dentro de la desviación estándar hubo una diferencia menor, entorno a un dígito como máximo, manteniéndose similar para cada clase de las variables, lo que nos indica consistencia entre ambos conjuntos.

Parte b

A partir de la Tabla 5 se puede observar que para el conjunto de entrenamiento se obtuvo una accuracy de 81% mientras que en test fue de 82%. Además, destaca que para la clase 0 se obtienen buenas métricas en Precision, Recall y F1-score, mientras que para la Clase 1 estas son bajas. Asimismo, se puede observar claramente el desbalance entre ambas clases, donde la Clase 0 es cerca de 5 veces más grande que la 1.

En la ecuación (2) del enunciado los valores máximos corresponden a las probabilidades a posteriori, las cuales combinan el prior y la verosimilitud de los atributos para cada clase. A partir de los resultados de la Tabla 4 para los Prior de cada clase podemos ver que se favorece a la Clase 0 con un 81,52% respecto a la Clase 1 que tiene solo un 18,48%. Esto indica que independientemente de los atributos, el modelo ya posee una tendencia a clasificar más hacia la clase 0.

Los valores para las probabilidades condicionales presentes en la Tabla 4 también indican que para las variables categóricas en Outlook la categoría sunny tiene más peso para la Clase 1 (0,551) que para la 0 (0,394), mientras que rainy y snow favorecen levemente a la Clase 0. Dentro de las mismas variables categóricas, para Windy las clases se encuentran más balanceadas en cuanto a las probabilidades.

En cuanto a las variables numéricas, además de la consistencia entre los conjuntos de entrenamiento y test mencionada en la parte a, podemos decir que las medias entre ambas clases son similares y por tanto no aportan valor de discriminación. En cuanto a Humidity la Clase 0 posee media 62 mientras que la Clase 1 un valor de 58. Asimismo Crowdedness tiene valores de 0,61 y 0,68 los que podrían ser potenciales variables que el modelo use para separar clases. Un detalle a destacar es que pese a que haya consistencia entre ambos conjuntos, esta puede deberse a que ambos están igualmente desbalanceados.

Asimismo, del histograma de los histogramas de las Figuras 4, 5 y ?? podemos observar como Windy esta equilibrada para ambas clases y conjuntos, mientras que Outlook presenta un claro desbalance entre las clases de ambos conjuntos. Para las variables numéricas se observan pequeñas diferencias entre ambos conjuntos para cada clase, y aunque estas tienden a seguir la misma distribución, aún pueden afectar las predicciones.

De las Tablas 7 podemos ver que en la matriz de confusión para el conjunto de entrenamiento predominan los True Negative con 4955 instancias, seguido de los False Negative con 1096. Además, destaca como un punto positivo la poca cantidad de False Positive con 44 instancias, aunque también como aspecto negativo la poca cantidad de True Positive con 37 instancias. Esta tendencia se repite para el conjunto de test, donde predominan los True Negative y

False Negative.

Además, centrándonos en la clase minoritaria (Clase 1) que previamente presentó bajos resultados en las métricas, podemos ver en la Tabla 8 que se obtuvo un 81,4% y 82,3% en accuracy para train y test respectivamente; 45,7% y 0,2% en precision; 3,3% y 0,8% en Recall, 99,1% y 99,4% en Specifity, 6,1% y 1,4% en F1-Score; 0,9% y 0,6% en Tasa de Falsos Positivos (FPR); 96,7% y 99,2% en la Tasa de Falsos Negativos (FNR) para los conjuntos de Train y Test respectivamente.

Estos resultados muestran que el modelo tiene un alto poder de identificar correctamente la clase negativa (Specifity cercana al 99% y muy bajo FPR), pero un desempeño muy deficiente en la identificación de la clase positiva (Recall menor al 4% en entrenamiento y aún menor en test). Esto se traduce en un gran número de falsos negativos.

Dentro de los hallazgos encontrados está que el modelo está fuertemente sesgado hacia la clase mayoritaria, lo que explica la alta Accuracy global, pero una utilidad práctica limitada para detectar la clase minoritaria. Dentro de las principales mejoras a considerar están las técnicas de Sampling para equilibrar las clases.

Parte c

Al utilizar un modelo de Regresión Logística se obtuvieron los coeficientes presentes en la Tabla 10 destacando que *num_Crowdedness* tuvo un valor de 2.85, indicando que es la variable más influyente en la probabilidad de que la clase objetivo (Play) sea positiva, otros coeficientes fueron positivos pero con valores menores, indicando que no tienen tanta influencia. Por otra parte, aquellos con valores negativos como *cat_Outlook_rainy* con -0.336 indican que si Outlook = Rainy, la probabilidad de que la clase objetivo sea positiva disminuye.

Finalmente, en base a las métricas obtenidas en la Tabla 9 para la Regresión Logística, y las de la Tabla 8 para Naïve Bayes podemos decir que de acuerdo a las métricas en Test, ambos modelos tienen una Accuracy similar (82,3% y 82,6%) y coinciden en tender hacia la clase mayoritaria (Clase 0). Sin embargo, Naïve Bayes es ligeramente mejor, porque aunque su Recall es bajo para Clase 1, la Regresión Logística no detectó instancias de esta clase (Recall = 0). Por tanto, la decisión para decidir que modelo es mejor debe considerar que la métrica de Accuracy no es la mejor en el contexto actual debido al desbalance de clases, pese a que es bastante alta para ambos modelos, al observar la clase minoritaria se observa que apenas predice correctamente, y por tanto, F1-Score es una métrica más balanceada que considera el desbalance de clases al combinar Precision y Recall. En este caso, Naïve Bayes resulta mejor al comparar las clases minoritarias (0,014 Naïve Bayes vs 0 Regresión Logística).

Respecto a los datos y rendimiento de los modelos, se puede decir que aunque hay 7.666 instancias registradas esto sigue siendo un tamaño relativamente bajo. Sumado a esto, la distribución de clases desbalanceada afecta fuertemente el mal rendimiento de ambos modelos en la clase 1. Con más datos distribuidos de forma balanceada, se esperaría que la Regresión Logística sea mejor que Naïve Bayes. Este funcionó relativamente mejor porque requiere pocos datos y es robusto bajo independencia condicional mientras que la regresión logística predijo solo la clase mayoritaria. Sin embargo, si el dataset fuese más grande y balanceado, la regresión logística podría llegar superar a Naïve Bayes, ya que no asume independencia entre atributos y puede estimar mejor las relaciones entre las variables.

A. Anexo

B. Pregunta 2

B.1. Parte a




Figure 1. Distribución de pasajeros por mes para conjuntos de entrenamiento y test.




Figure 2. Modelos polinomiales usando los datos de entrenamiento.

B.2. Parte c

Table 1. Resultados en test de la regresión polinómica (grados 1 a 5) con división 75/25 en train/test.

GRADO	MSE	MAE	R^2	MSLE
1	4989.5958	53.3019	0.1845	0.0237
2	5526.3070	66.3693	0.0968	0.0291
3	6626.6799	72.6747	-0.0831	0.0343
4	5054.9385	62.6496	0.1738	0.0267
5	283619.4316	392.5463	-45.3559	14.2885

B.3. Parte d

Table 2. Ajuste $\theta_1, \theta_2, \theta_3, \theta_4$ usando máxima verosimilitud con polinomio de grado 3.

	MSE	MAE	R^2	MSLE
TEST (25%)	6626.6798	72.6747	-0.0830	0.0343
PARÁMETROS	$\hat{\theta}_1$	$\hat{\theta}_2$	$\hat{\theta}_3$	$\hat{\theta}_4$
VALORES	3176.6749	0.0047	-0.0022	-0.5085




Figure 3. Variación de las métricas al cambiar el valor de θ_4 al inicializar el modelo.

B.4. Parte e

Table 3. Ajuste $\theta_5, \theta_6, \theta_7, \theta_8$ usando máxima verosimilitud con polinomio de grado 3.

	MSE	MAE	R^2	MSLE
TEST (25%)	4194.2650	52.2265	0.3144	0.0184
PARÁMETROS	$\hat{\theta}_5$	$\hat{\theta}_6$	$\hat{\theta}_7$	$\hat{\theta}_8$
VALORES	6.6717	0.5305	-52.4252	0.0220

C. Pregunta 3

C.1. Parte a

Table 4. Resultados del Naïve Bayes Classifier sobre el dataset de golf (train/test 80/20).

PRIORS DE LA CLASE			
CLASE 0		0.8152	
CLASE 1		0.1848	

PROBABILIDADES CONDICIONALES PARA OUTLOOK		
CLASE	VALOR	$P(x CLASE)$
0	SUNNY	0.394
0	OVERCAST	0.354
0	RAINY	0.198
0	SNOW	0.053
1	SUNNY	0.551
1	OVERCAST	0.315
1	RAINY	0.090
1	SNOW	0.044

PROBABILIDADES CONDICIONALES PARA WINDY		
CLASE	VALOR	$P(x CLASE)$
0	1	0.524
0	0	0.476
1	0	0.553
1	1	0.447

PARÁMETROS NUMÉRICOS (MEDIA Y DESVIACIÓN ESTÁNDAR)			
VARIABLE	CLASE	μ	σ
TEMPERATURE	0	13.46	8.11
TEMPERATURE	1	13.04	7.65
HUMIDITY	0	62.00	14.42
HUMIDITY	1	58.35	13.78
CROWDEDNESS	0	0.61	0.15
CROWDEDNESS	1	0.68	0.15

C.2. Parte b

Table 5. Reporte de métricas por clase en **Train**.

CLASE	PRECISION	RECALL	F1-SCORE	SUPPORT
CLASE 0	0.82	0.99	0.90	4999
CLASE 1	0.46	0.03	0.06	1133
ACCURACY			0.81	6132
MACRO AVG	0.64	0.51	0.48	6132
WEIGHTED AVG	0.75	0.81	0.74	6132

Table 6. Reporte de métricas por clase en **Test**.

CLASE	PRECISION	RECALL	F1-SCORE	SUPPORT
CLASE 0	0.83	0.99	0.90	1267
CLASE 1	0.20	0.01	0.01	266
ACCURACY			0.82	1533
MACRO AVG	0.51	0.50	0.46	1533
WEIGHTED AVG	0.72	0.82	0.75	1533

Table 7. Matrices de confusión del Naïve Bayes Classifier (Train y Test).

Table 7. Conjunto de Train

REAL	PREDICCIÓN	
	CLASE 0	CLASE 1
CLASE 0	4955	44
CLASE 1	1096	37

Table 7. Conjunto de Test

REAL	PREDICCIÓN	
	CLASE 0	CLASE 1
CLASE 0	1259	8
CLASE 1	264	2

Table 8. Naïve Bayes - Comparación de métricas por clase para Train y Test.

MÉTRICA	TRAIN	TEST
ACCURACY	0.814	0.823
PRECISION	0.819	0.827
RECALL	0.991	0.994
SPECIFICITY	0.033	0.008
F1-SCORE	0.897	0.903
FPR	0.967	0.992
FNR	0.009	0.006

MÉTRICA	TRAIN	TEST
ACCURACY	0.814	0.823
PRECISION	0.457	0.200
RECALL	0.033	0.008
SPECIFICITY	0.991	0.994
F1-SCORE	0.061	0.014
FPR	0.009	0.006
FNR	0.967	0.992




Figure 4. Distribución de valores en Windy para train y test.




Figure 5. Distribución de valores en Outlook para train y test.




Figure 6. Temperature - Clase 0




Figure 7. Temperature - Clase 1




Figure 8. Humidity - Clase 0




Figure 9. Humidity - Clase 1




Figure 10. Crowdedness - Clase 0




Figure 11. Crowdedness - Clase 1

Figure 12. Comparación de gráficas por variable, clase y conjuntos train/test.

C.3. Parte c

Table 9. Regresión Logística - Comparación de métricas por clase para Train y Test.

Table 9. Métricas Clase 0			Table 9. Métricas Clase 1		
MÉTRICA	TRAIN	TEST	MÉTRICA	TRAIN	TEST
ACCURACY	0.815	0.826	ACCURACY	0.815	0.826
PRECISION	0.815	0.826	PRECISION	0.000	0.000
RECALL (TPR)	1.000	1.000	RECALL (TPR)	0.000	0.000
SPECIFICITY	0.000	0.000	SPECIFICITY	1.000	1.000
F1-SCORE	0.898	0.905	F1-SCORE	0.000	0.000
FPR	1.000	1.000	FPR	0.000	0.000
FNR	0.000	0.000	FNR	1.000	1.000

Table 10. Coeficientes estimados en el modelo de Regresión Logística.

VARIABLE	COEFICIENTE
CAT__OUTLOOK_RAINY	-0.336031
CAT__OUTLOOK_SNOW	0.477981
CAT__OUTLOOK_SUNNY	0.240162
CAT__WINDY_I	-0.173554
NUM__TEMPERATURE	0.003243
NUM__HUMIDITY	-0.008215
NUM__CROWDEDNESS	2.848908