

Tarea 2

Fecha de entrega: 22 de septiembre, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Alvaro Márquez, Víctor Hernández.

Ayudante: Hayter Cortés.

Formato de entrega	PDF con extensión máxima de 5 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

P1 (20 %) - Bayes

Considere un test para determinar si una persona porta la infección Z . Asuma que la probabilidad que el test sea correcto es conocida, i.e., que la tasa de verdaderos positivos y la tasa de verdaderos negativos son iguales y conocidas. Asuma además que sabemos la probabilidad de portar la infección. 10.000 personas han sido diagnosticadas como positivas a Z según el test. El gobierno le encarga a usted hacer **una estimación del número de personas que no tienen la enfermedad habiendo sido diagnosticadas positivas**.

- (a) (3.5 pts) Modele el problema usando un teorema visto en clases. Explique cómo puede estimar el número y deduzca una expresión para dicha cantidad que dependa sólo de valores conocidos.

Indicación: Puede ser útil usar la ley de probabilidades totales.

- (b) (1 pts) Considere que la prevalencia de la enfermedad es de 1 cada 10 000 y que la probabilidad que el test sea correcto es de 95 %. Con esta información, estime el número de personas que NO tienen la enfermedad dentro de las 10.000 que testearon positivo a Z ¿Qué sucede si la probabilidad de que el test sea correcto es del 50 %? Comente en ambos casos.
- (c) (1.5 pts) Compare la diferencia entre el paradigma “frecuentista” y el paradigma “Bayesiano” al interpretar la probabilidades.

P2 (40 %) - Más sobre regresiones

En el archivo `data_p2.txt` están los datos de la cantidad de pasajeros de una aerolínea medidos de forma mensual. Los datos son de la forma $\{(x_i, y_i)\}_{i=1}^n$ donde x_i representa un mes, e y_i la cantidad de pasajeros transportados en el mes correspondiente.

El objetivo de esta pregunta es modelar la cantidad de pasajeros (y) respecto al tiempo (x). Para esto, se asumirá el siguiente modelo:

$$y = f_\theta(x) + \eta,$$

donde θ son los parámetros de la función f que se deben ajustar, y $\eta \sim N(0, \sigma_n^2)$ es ruido gaussiano.

Separe los datos en un conjunto de entrenamiento y otro de test. Considere que el 75 % de los datos son para entrenar (primeros 9 años) y el 25 % es de test.

1. (0.5 ptos) Cargue y grafique los datos de forma que los conjuntos de entrenamiento y de test sean fácilmente identificables.
2. (0.5 ptos) Utilice la función `polyfit` de `numpy` para ajustar un modelo polinomial de grado 1,2,3,4,5 con los datos de entrenamiento. Grafique las curvas obtenidas y su ajuste a los datos de test.
3. (0.5 ptos) Reporte el Error Cuadrático Medio (ECM), el Error Absoluto Medio (EAM), el Coeficiente de Determinación (R^2) y el Error Cuadrático Logarítmico Medio (MSLE). ¿Qué puede decir al respecto de los distintos valores que se obtienen de las métricas? ¿Qué métrica considera usted que sería mejor para este caso? ¿Qué comportamiento ocurre con cada una de las curvas ajustadas? ¿Qué es lo esperable cuando x crece? Lo anterior debe ser observado en los datos de test.

Como podrá observar, no es posible capturar el movimiento periódico de los datos usando sólo un polinomio. Denotemos por f^{pol} al polinomio que encontró en la parte anterior. Modelaremos la señal con el siguiente modelo:

$$y = f^{pol} + \theta_1 \sin(\theta_2 x + \theta_3) e^{\theta_4 x} + \eta,$$

con $\eta \sim N(0, \sigma_n^2)$.

4. (1.5 ptos) Ajuste $\theta_1, \theta_2, \theta_3, \theta_4$ usando máxima verosimilitud. Note que este modelo no es lineal en los parámetros, por lo que no se puede escribir una solución de forma exacta. Para encontrar los parámetros de máxima verosimilitud, construya la función de verosimilitud y optimice utilizando la función `minimize` de `scipy.optimize` usando el método BFGS. ¿Qué tan bueno es el ajuste encontrado? Reporte las métricas ECM, EAM, R^2 y MSLE.

Indicación: Puede ser útil ocupar $\theta_4 = 0.01$ como condición inicial. ¿Qué sucede si es utiliza otros valores de θ ?

El comportamiento de los datos no es sólo sinusoidal, por lo que agregaremos una última componente. Denotemos por $f^{pol-sin}$ a la función f_θ encontrada en la parte anterior. Agregue una segunda componente sinusoidal modulada por una exponencial al modelo, es decir:

$$y = f_\theta + \eta = f^{pol-sin} + \theta_5 \sin(\theta_6 x + \theta_7) e^{\theta_8 x} + \eta.$$

5. (2 ptos) Considere los parámetros de $f^{pol-sin}$ fijos e iguales a su resultado de la parte anterior. Nuevamente use máxima verosimilitud para encontrar $\theta_5, \theta_6, \theta_7, \theta_8$, optimizando con `minimize` y

BFGS. Evalúe su solución prediciendo el 25 % restante de los datos. Reporte las métricas ECM, EAM, R^2 y MSLE.

Indicación: Nuevamente, puede ser útil ocupar $\theta_5 = 0.01$ como condición inicial.

6. (1 pto) Presente sus resultados y discuta el método con el que los obtuvo, en particular, explique el rol de cada una de las componentes del modelo final. ¿Habría sido posible entrenar el modelo final de una vez? Evalúe los modelos ajustados en función de su verosimilitud y del error de predicción en el conjunto de evaluación.

P3 (40 %) - Modelo de Naïve Bayes

*Naïve Bayes Classifier*¹ es un modelo de probabilidades condicionales para clasificación, donde se asume que las categorías o atributos son mutuamente independientes dado el valor de la clase. Este modelo utiliza fuertemente el teorema de Bayes. Formalmente, el modelo se desarrolla de la siguiente forma: Considere $C_i \in C$, donde C son las clases, y C_i es la i -ésima clase con $i \in \{1, \dots, K\}$, con K el número de clases. Además, considere $X = (x_1, \dots, x_n)$ el vector de atributos para un dato con n atributos. Para un vector de atributos X y una clase C_i dada, tenemos que, por el teorema de Bayes, la probabilidad de C_i se puede escribir como:

$$\mathbb{P}(C_i|x_1, \dots, x_n) = \frac{\mathbb{P}(C_i)\mathbb{P}(x_1, \dots, x_n|C_i)}{\mathbb{P}(x_1, \dots, x_n)}. \quad (1)$$

Sin embargo, la premisa de independencia condicional de Naïve Bayes establece que:

$$\mathbb{P}(x_j|C_i, x_j, \dots, x_{j-1}, x_{j+1}, \dots, x_n) = \mathbb{P}(x_j|C_i),$$

para $j \in \{1, \dots, n\}$. Consecuentemente, la ecuación (1) se puede reescribir como:

$$\mathbb{P}(C_i|x_1, \dots, x_n) = \frac{\mathbb{P}(C_i) \prod_{j=1}^n \mathbb{P}(x_j|C_i)}{\mathbb{P}(x_1, \dots, x_n)}.$$

Recordando la Teoría de Bayes, tenemos que $\mathbb{P}(x_1, \dots, x_n)$ es difícilmente computable, además de ser constante para cada clase C_i . Entonces, queremos derivar el estimador MAP, proporcionalmente se obtiene que:

$$\mathbb{P}(C_i|x_1, \dots, x_n) \propto \mathbb{P}(C_i) \prod_{j=1}^n \mathbb{P}(x_j|C_i),$$

considerando el MAP obtenemos:

$$\hat{K} = \underset{i}{\operatorname{argmax}} \mathbb{P}(C_i) \prod_{j=1}^n \mathbb{P}(x_j|C_i), \quad (2)$$

de donde la clase predicha será $\hat{C} = C_{\hat{K}}$.

¹ Los modelos de Naïve Bayes hacen referencia a varios modelos que se derivan de forma similar a lo mostrado, que utilizan la condición o premisa de independencia condicional dado una clase. En esta pregunta se verá un caso puntual de estos.

El objetivo de esta pregunta es implementar el Naïve Bayes Classifier. Considere la base de datos de golf de `golf_dataset.csv`, donde la clase a predecir es *Play* y los a considerar son 2 variables categóricas (*Outlook* y *Windy*) y tres numéricas (*Temperature*, *Humidity* y *Crowdedness*). Las demás variables no las considere. Se pide lo siguiente:

1. (2 ptos) Implemente el Naïve Bayes Classifier. Separe los datos en un conjunto de entrenamiento y otro de test. Considere que el 80 % de los datos para entrenar y el 20 % es de test. Para esto utilice la función `train_test_split` de la librería `sklearn.model_selection`. Implemente el algoritmo para los datos de entrenamiento.

Indicación: Para implementar el algoritmo, debe encontrar las probabilidades $\mathbb{P}(x_j|C_i)$, $\forall i \in \{1, 2\}, \forall j \in \{1, \dots, n\}$. Para las variables categóricas, se deben encontrar las tablas de probabilidades condicionales, mientras que para las variables numéricas, debe asumir que $x_j|C_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$, y estimar μ_i y σ_i para cada clase con los estimadores usuales.

2. (2 ptos) Obtenga la predicción de las clases para los datos de test, comente brevemente sobre los valores dentro del máximo de (2) y la diferencia de los atributos de los datos de testeo. Haga una predicción de su clasificador para los datos de entrenamiento. Reporte la Matriz de Confusión, Accuracy, Precision, Recall, Specificity, F1-Score, Tasa de Falsos Positivos (FPR) y Tasa de Falsos Negativos (FNR).
3. (2 ptos) Implemente un modelo de Regresión Logística. Utilice la librería `sklearn`. Prediga las clases para los datos de entrenamiento y testeo. Compare los resultados obtenidos con el modelo de Naïve Bayes, utilizando las mismas métricas de la parte anterior. Reporte el valor de los coeficientes obtenidos en la Regresión Logit y comente, complementando con los resultados observados de Naïve Bayes ¿Cuál variable se puede decir que es más relevante? ¿Cuál modelo es mejor?, ¿según cuál métrica?, ¿Por qué utilizó tal métrica?, ¿Se puede decir algo sobre la cantidad de los datos y el rendimiento de los modelos?.