

Tarea 3

Fecha de entrega: 6 de octubre de 2025, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Alvaro Márquez, Víctor Hernández.

Ayudantes: Hayter Cortés.

Formato de entrega	PDF con extensión máxima de 5 páginas, con anexos (no cuentan en la extensión de páginas), con doble columna, abstract, título e integrante. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

P1. Validación Cruzada

En clases, se vio el enfoque de regresión logística desde dos puntos de vista, el enfoque discriminativo y el generativo. Para esta pregunta, considere la base de “Heart Failure Prediction” de `heartth.csv`, donde la clase a predecir es *HeartDisease*¹ y que las variables a considerar son todas las variables excepto `ChestPainType`. Las demás variables no las considere.

- Explique brevemente los enfoques discriminativos y generativos. Además, discuta y escriba como estos enfoques se expresan en la regresión logística.
- Separe los datos en un conjunto de entrenamiento y otro de test. Considere que el 80 % de los datos son para entrenar y el 20 % es de test. Para esto utilice la función `train_test_split` de la librería `sklearn.model_selection`, utilice el parámetro `stratify` adecuadamente. Reporte algunas estadísticas de interés para ambos conjuntos (entrenamiento y test), en base a la variable *HeartDisease*. ¿Son estas estadísticas similares? ¿Es la distribución obtenida de la variable *Cholesterol* similar en ambos conjuntos (genere un histograma o calcule métricas relevantes)? Comente.
- Implemente un modelo de Regresión Logística. Utilice la librería `sklearn`. Prediga las clases para los datos de entrenamiento y testeo. Reporte la Matriz de Confusión, Accuracy, Precision, Recall,

¹ <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

Specificity, F1-Score, Tasa de Falsos Positivos (FPR) y Tasa de Falsos Negativos (FNR) en ambos conjuntos. Comente sobre los resultados obtenidos, explique los resultados tanto desde un enfoque discriminativo como generativo.

- (d) Repita las partes anteriores considerando el 60 % de los datos para entrenar y el 40 % de test. ¿Cambiaron sus resultados? ¿Por qué? Comente al respecto.
- (e) Explique qué información entrega la curva ROC² y el área bajo la curva ROC (AUC)³ en problemas de clasificación binaria. Grafique la curva ROC y reporte la métrica AUC para las dos divisiones de datos de 80 %/60 % de entrenamiento. Comente al respecto. Utilice la librería `sklearn`.
- (f) **(BONUS)** Explique las funciones `KFold`, `StratifiedKFold`, `RepeatedKFold`, `LeaveOneOut` y `LeavePOut` de la librería `sklearn.model_selection`. Implemente todas estas validaciones cruzadas con parámetros y métricas a su elección. Reporte los resultados obtenidos. ¿Son los resultados obtenidos comparables? ¿Qué método de validación cruzada recomienda? ¿Por qué seleccionó la métrica que utilizó? ¿Tienen los modelos una buena generalización? Indicación: Para utilizar `LeavePOut`, obtenga una sub muestra de un 10 % del tamaño total del conjunto de datos y utilice $p = 2$. Esta validación cruzada es muy exhaustiva por lo que tiene un tiempo de cómputo considerable.

P2. Selección de modelos, optimización de parámetros

Para esta pregunta, considere la base de datos de golf de `golf_dataset.csv`, donde la clase a predecir es *Play* y las variables a considerar son 4 variables categóricas (*Outlook*, *Windy*, *Holiday* y *Season*) y tres numéricas (*Temperature*, *Humidity* y *Crowdedness*). Las demás variables no las considere.

- (a) Para las variables categóricas, genere variables *dummies*⁴.
- (b) De la función `LogisticRegression` de la librería `sklearn.linear_model` explique y expláyese acerca del rol que tienen los parámetros `penalty`, `C` y `class_weight`.
- (c) Considere el modelo de Regresión Logística y realice Validación Cruzada con $K = 5$ con todas las combinaciones posibles de los siguientes parámetros:
 - `penalty`:{'l1', 'l2', 'elasticnet'},
 - `C`:{0.1, 1, 10},
 - `class_weight`:{'balanced', None, {0 : 1, 1 : 5}}.

Para esto, se recomienda fuertemente utilizar la función `GridSearchCV` de `sklearn.model_selection`, o cualquier otra función que le permita realizar el experimento. Reporte los resultados obtenidos y las métricas AUC, Accuracy y F1-Score.

- (d) Sin realizar validación cruzada, considere que el 80 % de los datos son para entrenar y el 20 % de test, implemente 27 modelos con las combinaciones de los siguientes hiper parámetros:
 - `penalty`:{'l1', 'l2', 'elasticnet'},

² https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html

³ https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html

⁴ https://pandas.pydata.org/docs/reference/api/pandas.get_dummies.html

- `C`: {0.1, 1, 10},
- `class_weight`: {'balanced', None, {0 : 1, 1 : 5}}.

Denotemos como $\hat{\beta}_m$ al resultado de la estimación de los parámetros del modelo m con M el conjunto de modelos. Considere el vector de la norma de estos parámetros $\hat{\beta}_M = (||\beta_m||)_{m \in M}$. Genere un histograma con el vector $\hat{\beta}_M$. Discuta en como la selección de los parámetros afecta en la magnitud de estos coeficientes.

- (e) Obtenga el vector $\tilde{\beta}_m$ definido por $\tilde{\beta}_m = \frac{\beta_m}{||\beta_m||}$ para cada modelo $m \in M$. Cada componente de $\tilde{\beta}_m$ indica la contribución de su variable respectiva. Reporte qué variable tiene el mayor valor absoluto de $|\beta_m|$ para cada modelo ¿Qué puede decir al respecto de las variables que tienen mayor valor absoluto en $\tilde{\beta}_m$? ¿En qué afecta cada selección de parámetros en la magnitud de los valores de $\tilde{\beta}_m$? Genere un histograma con respecto a los resultados obtenidos de todos los vectores $\tilde{\beta}_m$ de los modelos y discuta acerca de la relevancia que se le otorga a cada variable. Puede ser un histograma agregando según el tipo de *penalty* utilizado, o un agregado de todos los histogramas. ¿Existe alguna combinación de hiperparámetros que tenga algún comportamiento distinto a los demás?
- (f) ¿Cuál es la mejor combinación de parámetros? ¿Según cual métrica? Discuta acerca de los resultados obtenidos con respecto a `penalty`, `C` y `class_weight`. ¿Qué problema aborda cada uno de los parámetros? ¿Qué interpretación hay detrás de los parámetros que tuvieron las mejores métricas?

P3. Comparación entre modelos de clasificación

Para esta pregunta, considere la base de “Heart Failure Prediction” de `hearth.csv`, donde la clase a predecir es *HeartDisease*⁵ y que las variables a considerar son todas las variables excepto `ChestPainType`.

- (a) Separe los datos en un conjunto de entrenamiento y otro de test. Considere que el 90 % de los datos son para entrenar y el 10 % es de test. Para esto utilice la función `train_test_split` de la librería `sklearn.model_selection`, utilice el parámetro `stratify` adecuadamente. Para las variables categóricas, genere variables *dummies*⁶.
- (b) Implemente los siguientes modelos de clasificación: Regresión Logística, Perceptron, Nearest Neighbors, Gaussian Naive Bayes y Linear Discriminant Analysis. Reporte el Accuracy, Precision, Recall, Specificity, F1-Score, Tasa de Falsos Positivos (FPR) y Tasa de Falsos Negativos (FNR) en los conjuntos de entrenamiento y testeo. Comente sobre los resultados obtenidos, relacione los resultados con el enfoque de cada uno de los modelos y las limitaciones de estos. ¿Cómo se podrían mejorar los resultados?
- (c) Grafique la curva ROC y reporte la métrica AUC para todos los modelos. Relacione los resultados obtenidos con los enfoques de cada uno de los modelos. ¿Qué relación tienen estos con la maximización de la métrica AUC?
- (d) Considere los siguientes conjuntos de variables:

⁵ <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

⁶ https://pandas.pydata.org/docs/reference/api/pandas.get_dummies.html

- Solo variables categóricas (Considerando ahora `ChestPainType`)
- Solo variables numéricas
- Todas las variables (Considerando ahora `ChestPainType`)

Aplique todos los modelos sobre cada uno de los conjuntos de variables. Calcule las métricas AUC, Accuracy y F1-Score. Discuta acerca de los resultados y comente acerca de cómo el enfoque de los modelos ayuda a mejorar la clasificación en los modelos que tienen mejores métricas.

- (e) **(BONUS)** Aplique un escalamiento de los datos, evitando el *Data Leakage*⁷. Explique y aplique los escalados de `RobustScaler`, `StandardScaler` y `quantile_transform` de la librería `sklearn.preprocessing`. ¿Tiene sentido aplicar estos escalados sobre variables binarias? Implemente los modelos de clasificación de la parte anterior, reporte los resultados y compare.
- (f) Desde un enfoque desde el punto de vista de modelos estadísticos y lo observado con respecto a los datos. ¿Cuál cree usted que es el mejor modelo sin y con escalado sobre los datos? ¿Por qué?

⁷ https://scikit-learn.org/stable/common_pitfalls.html