

Tarea 4

Fecha de entrega: 20 de octubre, 23.59hrs.

Tiempo de dedicación: 8 horas

Profesor: Francisco Vásquez L.

Auxiliares: Alvaro Márquez, Víctor Hernández.

Ayudantes: Hayter Cortés.

Formato de entrega	PDF con extensión máxima de 5 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

P1. Clasificación de Falla Cardíaca y Comparación de Modelos

Para esta pregunta, utilice los datos de [Predicción de Falla Cardíaca](#) que se encuentran en [Kaggle](#). El objetivo es predecir la presencia de enfermedad cardíaca (*HeartDisease*).

(a) Exploración Inicial y Preparación de Datos:

- Familiarícese con el dataset describiendo sus variables (categóricas y numéricas) y el objetivo de predicción.
- Realice un análisis exploratorio básico: calcule estadísticas descriptivas, visualice distribuciones y verifique si existen valores faltantes. Evalúe si el dataset presenta desbalance en la variable objetivo *HeartDisease*.
- Aplique las transformaciones necesarias a las variables: convierta las variables categóricas a un formato numérico (e.g., *dummy variables*) y considere si es necesario escalar/estandarizar las variables numéricas, justificando su elección (podría ser relevante para LDA).
- Divida el conjunto de datos procesado en entrenamiento (80 %) y prueba (20 %), utilizando estratificación respecto a la variable objetivo.

(b) **Modelo Base: Regresión Logística:**

- Entrene un modelo inicial de Regresión Logística (`sklearn.linear_model.LogisticRegression`) utilizando todas las variables preprocesadas del conjunto de entrenamiento. Puede usar los hiperparámetros por defecto o ajustarlos si lo considera necesario (e.g., `class_weight` si detectó desbalance).
- Evalúe este modelo base en los conjuntos de entrenamiento y prueba reportando la Matriz de Confusión, Accuracy, Precision, Recall y F1-Score. Comente brevemente el desempeño inicial.

(c) **Introducción a Criterios de Información:**

- Explique la motivación detrás del uso de criterios de información como AIC (Criterio de Información de Akaike) y BIC (Criterio de Información Bayesiano) para la selección de modelos. Presente sus fórmulas generales ($AIC = -2\hat{l} + 2d$, $BIC = -2\hat{l} + d\ln(N)$) y describa el significado de cada componente ($\hat{l}$: log-verosimilitud maximizada, d : número de parámetros estimados, N : tamaño de la muestra).
- Discuta cómo estos criterios penalizan la complejidad del modelo y en qué se diferencian sus penalizaciones. Relacione brevemente AIC con la teoría de la información (KL Divergence) y BIC con la inferencia Bayesiana.

(d) **Selección de Modelos de Regresión Logística:**

- Proponga y entrene al menos dos modelos adicionales de Regresión Logística (M_2 , M_3) que utilicen diferentes subconjuntos de las variables predictoras disponibles (además del modelo M_1 del punto b que usa todas las variables). Justifique brevemente la elección de los subconjuntos.
- Para cada uno de los tres modelos (M_1 , M_2 , M_3):
 - Calcule $\hat{l}$ (log-verosimilitud maximizada en el training set). (*Nota: Puede requerir `predict_log_proba` o `statsmodels`*).
 - Determine el número de parámetros d correspondientes.
 - Calcule los valores de AIC y BIC.
 - Adicionalmente, use validación cruzada (k-Fold, $k = 5$) en el training set para obtener una estimación robusta del rendimiento (e.g., F1-score promedio).
- Presente una tabla comparativa con los valores de AIC, BIC y la métrica de CV para M_1 , M_2 , M_3 . Indique qué modelo(s) son preferidos según cada criterio. Discuta si hay consistencia entre los criterios.

(e) **Análisis con Linear Discriminant Analysis (LDA):**

- Entrene un modelo LDA (`sklearn.discriminant_analysis.LinearDiscriminantAnalysis`) utilizando el mismo conjunto de entrenamiento (puede usar todas las variables preprocesadas o un subconjunto si lo justifica).
- Evalúe el rendimiento de LDA en el conjunto de prueba utilizando las mismas métricas estándar (Matriz de Confusión, Accuracy, Precision, Recall, F1-Score).
- Calcule la log-verosimilitud maximizada ($\hat{l}$) para el modelo LDA ajustado sobre el conjunto de entrenamiento.
- Determine el número de parámetros (d) estimados por el modelo LDA (considere los parámetros de las medias, la covarianza compartida y los priors de las clases: $d = (K - 1) + K \times M + M(M + 1)/2$ para K clases y M features).

- Calcule los valores de AIC y BIC para el modelo LDA.

(f) **Análisis con Support Vector Machine (SVM):**

- Entrene un modelo SVM para clasificación (`sklearn.svm.SVC`) utilizando el conjunto de entrenamiento. Puede comenzar con un kernel lineal y luego, si lo desea, explorar kernels no lineales (e.g., RBF) para investigar relaciones más complejas.
- Evalúe el rendimiento del modelo SVM en el conjunto de prueba utilizando las mismas métricas que en los casos anteriores (Matriz de Confusión, Accuracy, Precision, Recall y F1-Score).
- **Discusión sobre la Verosimilitud en SVM:**
 - A diferencia de la Regresión Logística y LDA, el SVM es un modelo inherentemente no probabilístico. Su objetivo no es modelar la distribución de probabilidad de los datos, sino encontrar un hiperplano que maximice el margen entre las clases. Estudie y describa brevemente qué técnicas se utilizan para poder abordar los SVC desde un punto probabilista. Plantee las limitaciones y ventajas al respecto.

(g) **Comparación Final y Discusión:**

- Compare el modelo LDA con los modelos de Regresión Logística (M_1, M_2, M_3) utilizando todas las métricas y criterios calculados (métricas de desempeño en test, AIC, BIC, métrica de CV).
- ¿Qué modelo final seleccionaría para predecir la falla cardíaca en este dataset? Justifique su elección considerando el balance entre rendimiento predictivo (evaluado en test y CV) y complejidad/parsimonia (evaluado por AIC/BIC).
- Reflexione sobre los supuestos de LDA (normalidad de features por clase, homocedasticidad) y si parecen cumplirse razonablemente en este dataset. ¿Cómo podría esto influir en la comparación con la Regresión Logística?
- Más allá de los supuestos específicos de LDA, ¿qué limitaciones generales podrían tener tanto LDA como la Regresión Logística para modelar las relaciones presentes en este dataset? Considere la posibilidad de relaciones no lineales o interacciones entre variables. ¿Cómo podría investigar formalmente su presencia e impacto?
- Analice la magnitud de las diferencias en los valores de AIC y BIC entre los modelos. ¿Cuán fuerte es la evidencia a favor del modelo seleccionado según estos criterios? ¿Existen reglas generales (heurísticas) para interpretar las diferencias ΔAIC o ΔBIC ? Investigue y comente brevemente.
- Incorpore el modelo SVM en la discusión final. Aunque no se puede comparar usando AIC/BIC, ¿cómo se posiciona su rendimiento (e.g., F1-score en el conjunto de prueba) frente al mejor modelo logístico y al modelo LDA? Reflexione sobre las situaciones en las que la falta de un marco de verosimilitud puede ser una desventaja (e.g., necesidad de cuantificar incertidumbre) y en las que el enfoque de maximización de margen del SVM podría ser superior.