

Tarea 5

Fecha de entrega: 10 de octubre, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Alvaro Márquez, Víctor Hernández.

Ayudantes: Hayter Cortés.

Formato de entrega	PDF con extensión máxima de 5 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

P1. Reducción de Dimensionalidad y SVC

Para esta pregunta, utilice los datos de [Breast Cancer Wisconsin \(Diagnostic\) Data Set](#) que se encuentran en [Kaggle](#). Este conjunto de datos posee diferentes variables asociadas a tumores. Con estos datos se considerará el problema de clasificación binaria discriminado entre tumores benignos y malignos, utilizando la variable (*diagnosis*).

- Análisis Exploratorio del Dataset:** Describa el conjunto de datos. Explique brevemente el significado de cada variable (consulte la información en el enlace proporcionado). Calcule y reporte estadísticas descriptivas relevantes para cada variable, agrupadas según la variable objetivo (*diagnosis*). Compare y comente si existen diferencias significativas en estas estadísticas entre los grupos.
- Reducción de dimensionalidad y visualización:** Aplique los siguientes métodos de reducción de dimensionalidad: PCA, t-SNE, UMAP e Isomap con $d = 2$. Realice esto sobre el conjunto de datos original y también sobre una versión estandarizada de los mismos. Seleccione los parámetros para cada método a su criterio. Para cada una de las 8 proyecciones resultantes (4 métodos x 2 conjuntos de datos), genere un gráfico en 2 dimensiones, coloreando los puntos según la variable *diagnosis*. Comente los resultados: ¿Cómo afecta la estandarización a las proyecciones? ¿Permiten estas proyecciones visualizar alguna separación o estructura en los datos con respecto a la variable objetivo? ¿Qué métodos no se pueden utilizar para proyectar nuevos datos? ¿Por qué?

- (c) Grafique la matriz de correlaciones (heatmap). ¿Existen variables que tengan alta correlación? ¿Cómo se espera que afecte esto a los modelos de SVM? ¿Qué método de reducción de dimensionalidad se podría utilizar para agrupar ciertas características? ¿Por qué?
- (d) Divida los datos (antes de cualquier estandarización para este ítem) en conjuntos de entrenamiento (80 %) y prueba (20 %). Utilice la función `train_test_split` de `sklearn.model_selection`, asegurándose de estratificar la división según la variable *diagnosis* mediante el parámetro `stratify`.
- (e) **Modelo SVC por defecto:** Considere la función `SVC` de la librería `sklearn.svm`. Explique detalladamente la función de los hiperparámetros `kernel`, `C` y `class_weight`. Entrene un modelo SVC utilizando los parámetros por defecto sobre el conjunto de entrenamiento. Luego, evalúe el modelo prediciendo las etiquetas para los conjuntos de entrenamiento y prueba. Reporte las siguientes métricas para ambos conjuntos: Matriz de Confusión, Accuracy, Precision, Recall, Specificity, F1-Score, Tasa de Falsos Positivos (FPR) y Tasa de Falsos Negativos (FNR). Comente los resultados obtenidos, prestando atención a posibles signos de sobreajuste o desbalance de clases.
- (f) **Curva ROC y Métrica AUC:** Explique como se realiza el cálculo de probabilidad de clase en el modelo SVC. Genere la curva ROC y calcule el área bajo la curva (AUC) para el modelo SVC entrenado en el ítem anterior, utilizando las predicciones sobre el conjunto de prueba. Utilice las herramientas de `sklearn`. Comente e interprete la curva y el valor de AUC.
- (g) **Optimización de hiperparámetros con validación cruzada:** Implemente una búsqueda de hiperparámetros para el modelo SVC utilizando validación cruzada con $K = 5$. Explore todas las combinaciones de los siguientes parámetros:

- `kernel`: {'linear', 'poly', 'rbf', 'sigmoid'}
- `C`: {0.1, 1, 10}
- `class_weight`: {'balanced', None, {0:1, 1:5}}

Utilice `GridSearchCV` de `sklearn.model_selection` sobre el conjunto de entrenamiento. Reporte la combinación de parámetros que optimiza el rendimiento. Con este mejor modelo, reporte las métricas AUC, Accuracy y F1-Score tanto para el conjunto de entrenamiento como para el de prueba. Compare estas métricas con las obtenidas anteriormente y discuta las diferencias.

- (h) **Discusión de hiperparámetros seleccionados:** Discuta los resultados de la optimización. Refiérase a la elección de los hiperparámetros `kernel`, `C` (interpretándolo como un parámetro de regularización/penalización) y `class_weight`. Explique qué problema o aspecto del modelado aborda cada uno de estos parámetros. ¿Qué interpretación puede dar a los valores de los hiperparámetros que resultaron en el mejor modelo SVC?
- (i) **Modelado sobre proyecciones de dimensionalidad reducida:** Utilizando las proyecciones a 2 dimensiones obtenidas en el ítem (b) (tanto las originales como las estandarizadas, excepto por t-SNE), aplique `GridSearchCV` con la misma grilla de parámetros para SVC definida en el ítem (g). Para cada una de las 8 proyecciones:
- (i) Reporte la mejor combinación de parámetros y las métricas (AUC, Accuracy, F1-Score) en el conjunto de prueba (deberá proyectar los datos de prueba usando el transformador ajustado en los datos de entrenamiento).
 - (ii) Compare el rendimiento (y los parámetros seleccionados) con el mejor modelo obtenido sobre los datos de mayor dimensionalidad. ¿Mejora o empeora el rendimiento? ¿A qué podría deberse?

Discuta brevemente si alguna técnica de reducción de dimensionalidad parece más prometedora para esta tarea de clasificación con SVC.

- (j) **Impacto del escalado de características:** Sobre el conjunto de datos original, aplique **RobustScaler** y **StandardScaler** de `sklearn.preprocessing`. Asegúrese de aplicar el escalado de forma separada a los conjuntos de entrenamiento y prueba para evitar el *Data Leakage*¹. Para cada tipo de escalado:
- (i) Entrene un modelo SVC utilizando la mejor combinación de hiperparámetros encontrada en el ítem (g). Reporte las métricas (AUC, Accuracy, F1-Score) en entrenamiento y prueba. Compare estos resultados con los obtenidos en el ítem (g) (sin este escalado explícito) y entre los dos tipos de escaladores.
 - (ii) Vuelva a ejecutar **GridSearchCV** (con la misma grilla de parámetros del ítem (g)) sobre los datos escalados. ¿Cambió la combinación óptima de hiperparámetros en comparación con la obtenida en (g)? ¿Mejoraron las métricas?
 - (iii) Seleccione un método de reducción de dimensionalidad a elección y aplique este método a los conjuntos de datos con los escalados **RobustScaler** y **StandardScaler**. Compare los resultados de la proyección obtenida. Comente las diferencias encontradas.
 - (iv) ¿Qué es lo esperable al aplicar un modelo de SVC sobre la proyección encontrada en el punto anterior? ¿A qué se deben los cambios?

Comente los hallazgos.

¹ Consulte: https://scikit-learn.org/stable/common_pitfalls.html