

Tarea 6

Fecha de entrega: 1 de diciembre, 23.59hrs.

Profesor: Francisco Vásquez L.

Auxiliares: Alvaro Márquez, Víctor Hernández.

Ayudantes: Hayter Cortés.

Formato de entrega	PDF con extensión máxima de 5 páginas, con anexos (no cuentan en la cantidad de páginas), con doble columna, abstract, título e integrante y referencias. Si hace su reporte en $\text{\LaTeX}$, utilice el template de la conferencia ICML disponible en este enlace , o bien uno de formato similar. Adicionalmente debe entregar el <i>jupyter notebook</i> (o el código que haya generado) con la resolución de la tarea y debe fijar semillas antes de los procesos aleatorios. El código en sí no será evaluado.
Recomendación	Presente y analice sus resultados, detallando la metodología utilizada. Incorpore gráficos para apoyar su análisis.
Criterios de evaluación	La tarea será evaluada en base a la claridad de la metodología y las explicaciones, la profundidad de la reflexión en las preguntas conceptuales, el desarrollo teórico y el dominio que el/la estudiante demuestre de la conexión entre la teoría y la aplicación.
Carácter de la tarea	Individual.

Modelos Basados en Árboles y Clusterización

Para esta pregunta, utilice los datos de [Breast Cancer Wisconsin \(Diagnostic\) Data Set](#) que se encuentran en [Kaggle](#). El objetivo de esta pregunta es estudiar los árboles de decisión y mezclas de modelos. Este conjunto de datos posee diferentes variables asociadas a tumores. Con estos datos se considerará el problema de clasificación binaria discriminado entre tumores benignos y malignos.

Preliminar

(Preliminar) Describa el dataset, explique brevemente qué representa cada variable (La información se encuentra en el mismo link). Reporte algunas estadísticas de interés de los datos agrupados en base a la variable *diagnosis*. ¿Son estas estadísticas similares?

- Explique como los modelos basados en árboles lidian con las variables *dummies*.
(Bonus) Cree una o más variables categóricas a su elección en base a su conocimiento a priori. Considere la variable a futuro para entrenar los modelos basados en árboles. Elija una variable continua clave (ej. `radius_mean`). Usando cuantiles (ej. `pd.qcut`), discretícela en 3 categorías (*bajo*, *medio*, *alto*). Use esta nueva variable categórica en el entrenamiento.
- Grafique la matriz de correlaciones (heatmap) asociado a las variables continuas del conjunto de datos. ¿Existen variables que tengan alta correlación? ¿Cómo se espera que afecte esta relación a los modelos basados en árboles? ¿Y a la clusterización?

Clusterización

- (c) Aplique el método de Reducción de dimensionalidad de PCA, grafique las primeras dos componentes principales según la variable *diagnosis*. Comente sobre los resultados obtenidos. ¿Es posible realizar alguna separación visual a los datos?
- Opcional.** En lo que sigue, en vez de utilizar el dataset original, puede considerar utilizar el proyectado por PCA. Explique qué característica sobre las variables puede argumentar su uso. ¿Qué ventajas y desventajas tiene realizar esto?
- (d) Encuentre alguna separación de los datos de manera no-supervisada con el método *K*-means sobre el conjunto de datos original. Para justificar su elección de número de clusters, además del método del codo (Elbow method), reporte y grafique el Silhouette Score para un rango de valores de *k* (ej. 2 a 10). Adicionalmente, para su *k* elegido, estudie y reporte el Adjusted Rand Index (ARI) comparando los clusters encontrados con las etiquetas reales (diagnosis). Comente sobre qué tan bien (o mal) la estructura no-supervisada captura la clasificación real. Grafique sus clusters encontrados en el gráfico dado por las componentes principales de PCA y comente.
- (e) Encuentre clusters con el método DBSCAN sobre el conjunto de datos original. Explique en qué consiste el algoritmo y sus principales parámetros. Grafique y compare con el método *K*-means. ¿Qué se puede decir de los clusters respecto a la variable objetivo de clasificación en cada caso? Argumente cómo influye la naturaleza de cada algoritmo en esto.
- (f) Aplique un modelo de Clustering Jerárquico Aglomerativo sobre el conjunto de datos. Grafique el dendrograma resultante utilizando el linkage **ward**. Justifique un punto de corte (o un número de *k* clusters) basándose en el dendrograma. Grafique estos clusters en las dos primeras componentes de PCA (similar a (d)) y compare los resultados cualitativamente con *K*-Means y DBSCAN.

Modelos basados en árboles

- (g) Separe los datos originales en un conjunto de entrenamiento y otro de test. Considere que el 80 % de los datos son para entrenar y el 20 % es de test. Para esto utilice la función `train_test_split` de la librería `sklearn.model_selection`, utilice el parámetro `stratify` adecuadamente.
- (h) De la función `DecisionTreeClassifier` de la librería `sklearn.tree` explique y expláyese acerca del rol que tienen los parámetros `criterion`, `min_samples_leaf`, `max_depth` y `random_state`. Utilice los parámetros que vienen por defecto y entrene el modelo con los datos de entrenamiento y prediga las clases para los datos de entrenamiento y testeo. Reporte la Matriz de Confusión, Accuracy, Precision, Recall, Specificity, F1-Score, Tasa de Falsos Positivos (FPR) y Tasa de Falsos Negativos (FNR). Comente sobre los resultados obtenidos. Utilice otro valor de `random_state` y reporte los resultados, ¿Son estos resultados distintos? ¿Por qué?
- (i) Grafique la curva ROC y reporte la métrica AUC. Comente al respecto. Utilice la librería `sklearn`.
- (j) Considere el modelo de `DecisionTreeClassifier` y realice Validación Cruzada con $K = 3$ con todas las combinaciones posibles de los siguientes parámetros:
- `criterion`: {'gini', 'entropy', 'log_loss'},
 - `min_samples_leaf`: {1, 2, 10},
 - `max_depth`: {2, 5, 15}.

Utilice `GridSearchCV` de `sklearn.model_selection`. Reporte los parámetros del mejor modelo. Utilice el mejor modelo obtenido y reporte las métricas AUC, Accuracy y F1-Score en los datos de entrenamiento y testeo. ¿Cuál es la mejor combinación de parámetros? ¿Cómo mejoran las métricas con respecto a lo obtenido en las partes anteriores?

- (k) Estudie y explique la propiedad `feature_importances_` de `DecisionTreeClassifier`. Grafique el valor asociado a cada variable y comente.
- (**Bonus**) Si es que creó la variable categórica, ¿El árbol la utiliza en sus primeras divisiones? ¿Cómo se compara su importancia con la de la variable continua original?
- (**Bonus**) Si es que utilizó el dataset proyectado por PCA, ¿Qué puede decir con respecto a cada componente principal? ¿Cómo se traduce esto en las variables originales?
- (l) Tome las etiquetas de los clusters generadas por K-Means (pregunta e) y añádalas como una nueva variable categórica al conjunto de datos original. Evalúe (usando validación cruzada) si esta nueva característica mejora el desempeño (ej. Accuracy o F1-Score) de un Árbol de Decisión simple (como el de la pregunta h). Comente por qué cree que esto ayuda (o no) al modelo.
- (**Opcional**) Considere esta nueva variable en lo que sigue de la tarea.

Modelos basados en árboles, profundización

- (m) Explique cómo se poda un árbol según el enfoque de **minimal cost complexity** y comente en qué consiste el parámetro de complejidad `ccp_alpha`.
- (n) Utilizando el método `cost_complexity_pruning_path`, grafique cómo cambia la profundidad (`max_depth`) del árbol y la cantidad de nodos de éste, en función de α . Comente sus resultados. Grafique cómo cambia el *accuracy* del modelo, tanto en el conjunto de entrenamiento como en el de validación, en función del parámetro de complejidad y determine qué valor utilizar, argumentando su respuesta. Fijando este valor, vuelva a graficar el árbol ya podado y comente sus resultados comparándolos con los obtenidos en la pregunta anterior.
- (ñ) Implemente un *bagging* de árboles (puede usar el método `BaggingClassifier` de scikit-learn), evalúe su desempeño respecto a la métrica *accuracy*, en el conjunto de entrenamiento y en el conjunto de prueba, y compárelo con los resultados obtenidos con un modelo *Random Forest* (bosque aleatorio). Comente sus resultados e indique cuáles son las diferencias entre hacer un *bagging* de árboles y un bosque aleatorio.
- (o) Investigue la capacidad de interpretabilidad del método de *Random Forest*. En particular, comente cómo estimar la importancia de las distintas variables predictoras sobre la variable de interés, y explique cómo se calcula.
- (p) ¿Que características deben tener los árboles para que usar *boosting* suponga la mejor ganancia? Argumente con argumentos vistos en clases y compruebe esto experimentalmente utilizando el método `GradientBoostingClassifier`, escogiendo parámetros adecuados para hacer las comparaciones. Comente con el caso del método de agregación *bagging*.
- (q) Compare los modelos *Random Forest*, *Gradient Boosting* y *bagging* (siempre utilizando árboles como modelo de base). Compare los resultados en su conjunto de test para varias elecciones de K , donde K es el número de estimadores. Concluya cuál es el mejor modelo para clasificar en este caso.

Generalización

- (r) Aplique un escalado de **RobustScaler** y **StandardScaler** evitando el *Data Leakage*¹ de la librería `sklearn.preprocessing`.
- (s) Aplique algún modelo basado en árboles a su elección sobre el conjunto de datos original y sobre los dos nuevos conjuntos de datos escalados. Compare los resultados obtenidos en términos de F1-Score.
- (t) ¿Son estos resultados similares? Explique teóricamente, basándose en el mecanismo de división (split criterion) que utiliza un árbol de decisión (ej. Gini, Entropía), por qué se espera (o no) que transformaciones monotónicas como **StandardScaler** y **RobustScaler** afecten el rendimiento del modelo.

¹ https://scikit-learn.org/stable/common_pitfalls.html